

CSM: Cloud Sentiment Model

基于BERT和云模型的不确定性情感识别模型（南京邮电大学不确定性人工智能大作业）
输入一段文字，模型预测该段文字是积极还是消极情感，并给出不确定度

环境配置

1. 克隆仓库并安装依赖，推荐使用 python3.10

```
git clone https://github.com/SUC-DriverOld/Cloud-Sentiment-Model
cd Cloud-Sentiment-Model
conda create -n csm python=3.10 -y
conda activate csm
pip install torch torchvision torchaudio --index-url
https://download.pytorch.org/whl/cu126
pip install -r requirements.txt
```

2. 从 Huggingface 下载预训练的BERT模型 [chinese-roberta-wwm-ext-large](#)，按照下面的文件夹结构放置到 `pretrain` 文件夹下。只需要下载以下文件即可，其余文件不必下载。如果想要使用其他 bert 预训练模型，可以修改配置文件中的 `bert` 参数。

```
# 以chinese-roberta-wwm-ext-large为例，在pretrain文件夹下需要新建文件夹chinese-
roberta-wwm-ext-large
pretrain
├── chinese-roberta-wwm-ext-large
│   ├── added_tokens.json
│   ├── config.json
│   ├── pytorch_model.bin
│   ├── special_tokens_map.json
│   ├── tokenizer.json
│   ├── tokenizer_config.json
│   └── vocab.txt
# 对应的配置文件
bert:
  download: false          # 是否下载预训练模型，如果手动下载了，可以设置为false
  cache_dir: "pretrain"    # 自动下载的预训练模型存放路径
  model: "pretrain/chinese-roberta-wwm-ext-large" # 手动加载的模型路径，或者自动模型
的Huggingface仓库地址
```

数据集制作&修改配置文件

1. 数据集可以从 [ChineseNlpCorpus](#) 获取。
2. 可以使用多个 `.csv` 或 `.tsv` 文件作为数据集。将他们存放到同一个文件夹下，然后在配置文件 `configs/config.yaml` 中修改 `data.path` 为你的数据集存放路径即可。

- 数据集必须是以下面的格式（以csv为例），其中 `label` 列表示标注，每个标注对应的情感在配置文件 `model.labels` 中定义，`text` 列的值是训练文本。其余列可有可无，不影响训练。

```
# 例如以下csv格式的数据集
label,text
1,帅的呀，就是越来越爱你！[爱你][爱你][爱你]
1,美~~~~~[爱你]
1,梦想有多大，舞台就有多大！[鼓掌]
0,写点儿字容易吗？降税降税[怒骂]
0,可惜啊！它们不是我的啊！[泪][泪]800000啊

# 以及配置文件model.labels的值
labels:
  0: "Negative"
  1: "Positive"
```

- 按需修改配置文件，配置文件位于 `configs/config.yaml`，有关 `models` 的参数说明如下：

```
model:
  cloud_drop_num: 512      # 云模型云滴数量
  cloud_dim: 16            # 模型维度大小
  attention: false        # 是否使用attention
  labels:                  # 情感标签，可扩充，必须和训练数据中的label列对应
    0: "Negative"
    1: "Positive"
  features:                # 分类器隐藏层维度，可扩充
    - 256                  # 第一个值需要小于cloud_drop_num * cloud_dim
    - 64
    - 16                   # 最后一个值需要大于标签数量
  dropout: 0.2             # 分类器的dropout率
```

训练

- 使用下面的命令开始训练，第一次开始训练时，会进行数据预处理（速度较慢）。之后如果继续训练，会直接加载上一次预处理后的数据。

```
python train.py -c path/to/config.yaml
```

- 如果需要继续训练，可以使用 `-m` 传入初始模型，例如

```
python train.py -c path/to/config.yaml -m path/to/last/model.ckpt
```

推理

推理使用 `inference.py`，该脚本有两种模式。一次性推理和对话类的交互推理。

1. 一次性推理，使用下面的命令，其中 `-m` 传入训练好的模型，`-t` 传入需要推理的文本。注意如果文本中带有空格则需要使用引号将文本括起来。

```
python inference.py -m path/to/last/model.ckpt -t '你好呀，今天天气真好!'

# 输出结果
Loading tokenizer and model...
[Input]: 你好呀，今天天气真好!
[Prediction]: Positive, [Uncertainty]: 0.2147147823125124
```

2. 对话类的交互推理，使用下面的命令，其中 `-m` 传入训练好的模型。不需要输入文本。如果想退出聊天，按下 `Ctrl+C` 即可。

```
python inference.py -m path/to/last/model.ckpt

# 输出结果
Loading tokenizer and model...
>>> 你好呀，今天天气真好!
Prediction: Positive, Uncertainty: 0.2147147823125124
>>> 我太难受了!
Prediction: Negative, Uncertainty: 0.08376982249319553
```

3. 若需要指定最大推理文本长度，可以传入参数 `--max_length`，默认为128。
4. 若想要使用自定义配置文件，而不使用模型内置的配置文件，可以传入参数 `-c` 指定配置文件路径。但需要注意配置文件需要和模型匹配，否则会报错。

参考

- 中文 BERT-wwm | [Chinese-BERT-wwm](#)
- 中文 自然语言处理 语料/数据集 | [ChineseNlpCorpus](#)