

数据挖掘

- ✓ 本文档遵循知识共享署名-非商业性使用-相同方式共享 (CC BY-NC-SA 4.0) 协议
- 本文档内容为2024-2025学年第二学期期末考试重点，结合书本知识+大模型编写，大模型主要用于解释概念，举例，便于理解
- 开卷考试**，期末70%，平时30%

教材（这本书写的一坨，翻译也一坨）：



数据挖掘（原书第3版）(Jiawei Han, Micheline Kamber, Jian Pei, ...)
58.11MB



✓ 2024-2025学年第二学期期末考试重点

第一章

- P5 数据挖掘步骤
- P11 频繁模式 例1.7
- P14 支持度，置信度计算

第二章

- P27-29 各类属性的判断
- P30 中心趋势度量：均值，中位数，众数计算 例2.6 2.7 2.8 2.9
- P32 极差，四分位数，方差，标准差 例2.10 2.11 盒图要会画
- P34 分位数图，分位数-分位数图 例2.13 公式2.7
- P45 数据矩阵和相异性矩阵计算 例2.17 2.18
- P48 闵可夫斯基距离：四个距离的定义 例2.21 2.22
- P52 余弦相似性 例2.23

第三章

- P59 分箱 图3.2
- P63 例3.1 卡方分布 公式 3.1 3.2
- P65 协方差 例3.2
- P75 最小-最大规范化，z分数规范化 例3.4 3.5

- P76 小数定标 例3.6
- Kmeans算法的处理流程

第六章

- P161 apriori算法生成关联规则 例6.4
- P166 FP-growth算法
- P165 散列 图6.5
- P167 图6.7 FP树要会画（结合FP算法）
- P169 垂直数据格式找频繁模式
- P172 例6.8 lift计算
- P172-173 全置信度，最大置信度，kulczynski，余弦

第七章

- P188 定义7.1 定义7.2 零事务问题 例7.5
- P189 定义7.3 例7.6 基于Kulczynski度量的负相关模式

第八章

- P217 信息增益计算 例8.1
- P220 增益率 例8.2 基尼指数 例8.3
- P229 例8.4 高斯朴素贝叶斯
- P230 例8.5 拉普拉斯校准避免零概率问题
- P231 IF-THEN规则分类 例8.6
- P232 由决策树提取规则 例8.7
- P237 真正例，真负例，假正例，真假负例
- P239 灵敏性和特效性 例8.9 精度和召回率 例8.10
- P244 ROC曲线画图

第九章

- P263 例9.1 后向传播算法

第十章

- P295 例10.2 K-均值会计算第一轮
- P300 四个距离公式：最小，最大，均值，平均

第十一章

- P328 例11.7 EM算法的模糊聚类第一轮计算
- P341 例11.19 基于测地距的度量

第一章

P5 数据挖掘步骤

- 数据清理（消除噪声和删除不一致数据）。
- 数据集成（多种数据源可以组合在一起）。
- 数据选择（从数据库中提取与分析任务相关的数据）。
- 数据变换（通过汇总或聚集操作，把数据变换和统一成适合挖掘的形式）。
- 数据挖掘（基本步骤，使用智能方法提取数据模式）。
- 模式评估（根据某种兴趣度度量，识别代表知识的真正有趣的模式。）。
- 知识表示（使用可视化和知识表示技术，向用户提供挖掘的知识）。

P11 频繁模式 例1.7

频繁模式是指在数据集中频繁出现的项目、项目集、子序列或子结构。

- 超市购物数据中，{牛奶,面包}的组合经常一起被购买
- 网站访问日志中，用户经常按"首页→产品页→购物车"的顺序浏览

具体例子：在以下交易数据中：

代码块

- 1 交易1：{牛奶，面包，鸡蛋}
- 2 交易2：{牛奶，面包}
- 3 交易3：{牛奶，鸡蛋}
- 4 交易4：{面包，鸡蛋，啤酒}

- 单项频繁模式：牛奶(出现3次)，面包(3次)，鸡蛋(3次)
- 二项集频繁模式：{牛奶,面包}(2次)，{牛奶,鸡蛋}(2次)，{面包,鸡蛋}(2次)

关联规则 (Association Rule)：表示数据项之间存在的"如果...那么..."关系，形式为 $X \rightarrow Y$ 。具体例子，从上面的购物数据中，可以挖掘出关联规则：

- {牛奶} $\rightarrow$ {面包} (支持度=2/4，置信度=2/3)
 - 支持度：2次交易同时包含牛奶和面包，共4次交易。所分析的交易中，有2/4的交易牛奶和面包一起购买。
 - 置信度：3次交易包含牛奶，其中2次也包含面包。如果顾客购买牛奶，则购买面包的概率是2/3

P14 支持度，置信度计算

代码块
交易1: {牛奶, 面包, 尿布}
2 交易2: {可乐, 面包, 尿布, 啤酒}
3 交易3: {牛奶, 尿布, 啤酒, 鸡蛋}
4 交易4: {面包, 牛奶, 尿布, 啤酒}
5 交易5: {面包, 牛奶, 尿布, 可乐}

1. 支持度(Support)计算

定义: 支持度表示项集在所有交易中出现的频率, 即包含该项集的交易占总交易的比例。

公式:

$$\text{support}(X \Rightarrow Y) = P(X \cup Y) = \frac{\text{包含X和Y的交易数}}{\text{总交易数}}$$

示例1: 计算规则 {牛奶} → {尿布} 的支持度

- 同时包含牛奶和尿布的交易: 交易1、交易3、交易4、交易5 → 共4笔
- 总交易数: 5笔
- 支持度 = $4/5 = 0.8$ (或80%)

示例2: 计算规则 {面包} → {啤酒} 的支持度

- 同时包含面包和啤酒的交易: 交易2、交易4 → 共2笔
- 支持度 = $2/5 = 0.4$ (或40%)

2. 置信度(Confidence)计算

定义: 置信度表示在包含X的交易中, 也包含Y的条件概率。

公式:

$$\text{confidence}(X \Rightarrow Y) = P(Y|X) = \frac{\text{包含X和Y的交易数}}{\text{包含X的交易数}}$$

示例1: 计算规则 {牛奶} → {尿布} 的置信度

- 包含牛奶的交易: 交易1、交易3、交易4、交易5 → 共4笔
- 其中也包含尿布的: 交易1、交易3、交易4、交易5 → 4笔
- 置信度 = $4/4 = 1.0$ (或100%)

示例2: 计算规则 {面包} → {啤酒} 的置信度

- 包含面包的交易: 交易1、交易2、交易4、交易5 → 共4笔
- 其中也包含啤酒的: 交易2、交易4 → 2笔
- 置信度 = $2/4 = 0.5$ (或50%)

第二章

P27-29 各类属性的判断

1. 标称属性 (Nominal Attribute)

- **定义：**表示类别或名称的属性，无顺序关系
- **特点：**值之间只是不同的名称，没有顺序或量化关系。可以进行" $=$ "和" $\neq$ "比较，但不能进行大小比较
- **示例：**颜色：红、绿、蓝；性别：男、女；职业：教师、医生、工程师

2. 二元属性 (Binary Attribute)

- **定义：**只有两种状态的特殊标称属性 (0/1)
- **分类：****对称二元属性：**两种状态同等重要(如性别：男/女)；**非对称二元属性：**一种状态比另一种更重要(如HIV检测：阳性/阴性)
- **示例：**是否毕业：是/否；开关状态：开/关

3. 序数属性 (Ordinal Attribute)

- **定义：**值之间有有意义的顺序关系，但差值无明确意义
- **特点：**可以进行排序比较($>$, $<$)，但差值不能进行数学运算
- **示例：**教育程度：小学 $<$ 初中 $<$ 高中 $<$ 大学 $<$ 研究生；产品评级：差 $<$ 一般 $<$ 良 $<$ 优；军衔：士兵 $<$ 下士 $<$ 中士 $<$ 上士

4. 数值属性 (Numeric Attribute)

- **定义：**可以用数字表示的定量属性
- **子分类：**
 - **区间标度属性 (P28)：**用相等的单位尺度度量。区间属性的值有序，可以为正、0或负。因此，除了值的秩评定之外，这种属性允许比较和定量评估值之间的差。
 - **比率标度属性(P29)：**具有固有零点的数值属性。也就是说，如果度量是比率标度的，则可以说一个值是另一个的倍数（或比率）。此外，这些值是有序的，因此可以计算值之间的差，也能计算均值、中位数和众数。

5. 离散属性 (Discrete Attribute)

- **定义：**只能取有限或可数无限个值的数值属性
- **特点：**通常是整数；值之间有明确的"间隙"
- **示例：**家庭成员数量：1,2,3,...；某商品被购买次数；班级学生人数

6. 连续属性 (Continuous Attribute)

- **定义：**可以取无限多个值的数值属性，值之间无间隙

- **特点：**通常是实数；理论上可以在任意两个值之间插入新值
- **示例：**温度：36.5°C, 37.2°C,...； 体重：65.3kg, 70.8kg,...； 时间：1.25秒, 3.789秒,...

代码块

- ```
1 属性
2 |—— 定性属性 (Categorical)
3 | |—— 标称属性 (Nominal)
4 | |—— 二元属性 (Binary)
5 | |—— 序数属性 (Ordinal)
6 |—— 定量属性 (Numeric)
7 | |—— 离散属性 (Discrete)
8 | |—— 连续属性 (Continuous)
```

P30 中心趋势度量：均值中位数众数计算 例2.6 2.7 2.8 2.9

1. 均值 (Mean)

**定义：**所有数据的总和除以数据的个数。

**计算公式：**

$$\text{均值} = \frac{\sum_{i=1}^n x_i}{n}$$

**特点：**对极端值敏感；适用于数值型数据；所有数据都参与计算

2. 中位数 (Median)

**定义：**将数据按大小顺序排列后，位于中间位置的值。

**计算方法：**将数据从小到大排列；如果数据个数n为奇数：中位数 = 第  $\frac{n+1}{2}$  个数据；如果数据个数n为偶数：中位数 = 第  $\frac{n}{2}$  个和第  $\frac{n}{2} + 1$  个数据的平均值

**特点：**不受极端值影响；适用于序数数据和数值数据；当数据有偏态分布时，比均值更能代表数据中心

3. 众数 (Mode)

**定义：**数据中出现次数最多的数值。

**计算方法：**统计每个数值出现的频率找出出现频率最高的数值（可能有多个众数）

**特点：**可用于所有测量尺度的数据（标称、序数、数值）；可能不存在或多于一个；不受极端值影响；对于分类数据，众数是唯一可用的集中趋势度量

4. 中列数 (Midrange)

**定义：**中列数是数据集的最小值和最大值的简单平均值，是一种测量数据集中趋势的简单方法。

$$\text{中列数} = \frac{\text{最小值} + \text{最大值}}{2}$$

## P32 极差，四分位数，方差，标准差 例2.10 2.11 盒图要会画

### 1. 极差 (Range)

定义：数据集的最大值与最小值之差，反映数据的离散程度。

公式：极差 = 最大值 - 最小值

示例：数据集 [3, 5, 7, 9, 11] 极差 = 11 - 3 = 8

### 2. 四分位数 (Quartiles)

定义：将数据按大小排序后分为四等份的三个分割点 (Q1、Q2、Q3)。

- Q1 (第一四分位数)：25%的数据小于等于它。
- Q2 (中位数)：50%的数据小于等于它。
- Q3 (第三四分位数)：75%的数据小于等于它。

计算方法 (以Q1为例，n为数据个数)：

1. 数据排序后，位置  $k = \frac{1}{4}(n + 1)$
2. 若k为整数，Q1为第k个值；否则为相邻两值的加权平均。

示例：

数据集 [1, 3, 5, 7, 9, 11, 13, 15] (n=8)

- Q1位置 =  $0.25 \times (8+1) = 2.25 \rightarrow$  第2和第3个值的加权平均：  $3 + 0.25 \times (5-3) = 3.5$
- Q2 (中位数) =  $(7+9)/2 = 8$
- Q3位置 =  $0.75 \times 9 = 6.75 \rightarrow 11 + 0.75 \times (13-11) = 12.5$

### 3. 方差 (Variance)

定义：数据与均值之差的平方的平均值，衡量数据离散程度。

公式 (总体方差)：

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

样本方差 (分母用n-1)：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

示例：

数据集 [2, 4, 6]，均值  $\bar{x} = 4$

$$\text{方差} = \frac{(2-4)^2 + (4-4)^2 + (6-4)^2}{3} = \frac{4+0+4}{3} = 2.67$$

#### 4. 标准差 (Standard Deviation)

定义：方差的平方根，与原数据单位一致。

公式：

$$\sigma = \sqrt{\sigma^2} \quad \text{或} \quad s = \sqrt{s^2}$$

示例：

上述数据方差为2.67  $\rightarrow$  标准差 =  $\sqrt{2.67} \approx 1.63$

#### 5. 盒图 (箱线图, Box Plot) 绘制方法

用途：直观展示数据的四分位数、极值及异常值。

步骤：

##### 1. 计算关键值：

- 最小值、Q1、Q2 (中位数)、Q3、最大值。
- IQR (四分位距) = Q3 - Q1。
- 异常值边界： 下限 = Q1 - 1.5 × IQR； 上限 = Q3 + 1.5 × IQR

##### 2. 绘制图形：

- 箱子：从Q1到Q3，中位数 (Q2) 在箱内标线。
- 虚线：从箱子两端延伸至最小值/最大值 (不超异常值边界)。
- 异常值：超出边界的点单独标记 (如 “○”)。

示例：

数据集 [1, 2, 5, 6, 7, 9, 12, 15, 18, 25]

- Q1=5, Q2=8, Q3=15, IQR=10
- 异常值边界：下限=5-15=-10 (无)，上限=15+15=30  $\rightarrow$  25在范围内，无异常值。

#### P34 分位数图，分位数-分位数图 例2.13 公式2.7

##### 1. 分位数图 (Quantile Plot)

定义

- 展示单个数据集中所有数据点的分位数位置，横轴为数据值，纵轴为累积百分比 (分位数)。
- 用途：观察单变量数据的分布形态 (如是否对称、偏态)。

绘制步骤

- 排序数据：将数据从小到大排列。



2. 计算分位数：对每个数据点  $x_i$ ，计算其对应的分位数（累积比例）：

$$F(x_i) = \frac{i - 0.5}{n} \quad (\text{常用公式, } i \text{ 为排序后的位置, } n \text{ 为数据总数})$$

3. 绘图：

- 横轴：排序后的数据值  $x_i$ 。
- 纵轴：分位数  $F(x_i)$ （范围0~1或0%~100%）。

示例数据集：[3, 5, 7, 9, 11] (n=5)

| 数据 $x_i$ | 排序位置 (i) | 分位数 $F(x_i)$      |
|----------|----------|-------------------|
| 3        | 1        | $(1-0.5)/5 = 0.1$ |
| 5        | 2        | 0.3               |
| 7        | 3        | 0.5               |
| 9        | 4        | 0.7               |
| 11       | 5        | 0.9               |

## 2. 分位数-分位数图 (Q-Q Plot)

定义

- 比较两个数据分布的分位数是否相似，横轴为理论分布（如正态分布）的分位数，纵轴为实际数据的分位数。
- 用途：检验数据是否服从某理论分布（如正态性检验）。比较两个数据集的分布是否一致。

绘制步骤（以正态分布检验为例）

- 排序数据：将实际数据  $x_i$  从小到大排列。
- 计算理论分位数：对每个  $x_i$ ，计算其理论分位数  $z_i$ （标准正态分布的分位数）：

$$z_i = \Phi^{-1} \left( \frac{i - 0.5}{n} \right)$$

其中  $\Phi^{-1}$  是标准正态分布的逆累积分布函数。

- 绘图：横轴：理论分位数  $z_i$ 。纵轴：实际数据值  $x_i$ 。
- 解读：若点近似落在一条直线上，说明数据服从正态分布。

## 3. 关键区别

| 特征 | 分位数图 (Quantile Plot) | Q-Q Plot |
|----|----------------------|----------|
|    |                      |          |

|      |              |                    |
|------|--------------|--------------------|
| 横轴   | 实际数据值        | 理论分布分位数（或另一数据集分位数） |
| 纵轴   | 数据的分位数（累积比例） | 实际数据值（或另一数据集分位数）   |
| 用途   | 观察单变量分布形态    | 检验分布假设或比较两个分布      |
| 理论分布 | 不涉及          | 需指定（如正态分布、均匀分布等）   |

P45 数据矩阵和相异性矩阵计算 例2.17 2.18

1. 数据矩阵

- 定义：存储数据对象的矩阵，每行代表一个对象，每列代表一个属性（特征）

$$\begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix}$$

- n：对象数量 m：属性数量

2. 相异性矩阵

- 定义：对称矩阵，记录所有对象两两之间的相异性（距离或不相似性），对角线为0

$$\begin{bmatrix} 0 & d(1,2) & \cdots & d(1,n) \\ d(2,1) & 0 & \cdots & d(2,n) \\ \vdots & \vdots & \ddots & \vdots \\ d(n,1) & d(n,2) & \cdots & 0 \end{bmatrix}$$

- d(i,j)：对象i和j的相异性，满足d(i,j) = d(j,i)。

3. 标称属性之间的相异性

- 标称属性：无序的类别属性（如颜色、性别）。
- 相异性度量：通过不匹配的比例计算。
- 计算公式： $d(i,j) = \frac{\text{不匹配的属性数}}{\text{总属性数}}$
- 示例：

数据集（两个对象，属性：颜色、性别、职业）：

- 对象1：{红色, 男, 教师}
- 对象2：{蓝色, 男, 医生}

计算：

- 不匹配属性：颜色、职业 → 2个
- 总属性数：3

- 相异性:  $d(1, 2) = \frac{2}{3} \approx 0.67$
- 相似性:  $sim(i, j) = 1 - d(i, j)$

## 4. 二元属性之间的相异性

### 二元属性分类

- 对称二元属性:** 两种状态同等重要 (如性别: 男/女)。
- 非对称二元属性:** 一种状态更重要 (如HIV检测: 阳性/阴性)，通常用1表示重要状态。

### 相异性度量 (sim(i, j)称为Jaccard系数)

- 适用场景:** 非对称二元属性 (忽略“0-0”匹配)。
- 公式:**

$$d(i, j) = \frac{\text{非匹配的重要状态数}}{\text{涉及重要状态的总数}} = 1 - \frac{|A \cap B|}{|A \cup B|}$$
$$sim(i, j) = 1 - d(i, j)$$

- A, B: 对象i和j的属性集合。

### 示例: 4名患者的症状数据

#### 1. 数据矩阵 (二元属性)

| 患者ID | 发烧 (F) | 咳嗽 (C) | 头痛 (H) | 恶心 (N) | 乏力 (W) |
|------|--------|--------|--------|--------|--------|
| P1   | 1      | 0      | 1      | 1      | 0      |
| P2   | 0      | 1      | 1      | 0      | 1      |
| P3   | 1      | 1      | 0      | 1      | 0      |
| P4   | 0      | 0      | 1      | 0      | 1      |

- 1:** 症状存在 **0:** 症状不存在

#### 2. 相异性计算 (Jaccard距离) 忽略“0-0”匹配 (非对称二元属性)

步骤: 对每对患者, 统计以下数量:

- a: P1和P2均出现1的属性数 ( $A \cap B$ )。
- b: P1为1而P2为0的属性数。
- c: P1为0而P2为1的属性数。
- d: P1和P2均为0的属性数 (忽略)。

计算:  $d(i, j) = \frac{b + c}{a + b + c}$

3. 逐对计算示例

P1 vs P2

- 症状向量：
  - P1: [F=1, C=0, H=1, N=1, W=0]
  - P2: [F=0, C=1, H=1, N=0, W=1]
- 匹配统计：
  - $A \cap B$  (均为1) : 头痛 (H)  $\rightarrow a = 1$
  - P1=1且P2=0: 发烧 (F)、恶心 (N)  $\rightarrow b = 2$
  - P1=0且P2=1: 咳嗽 (C)、乏力 (W)  $\rightarrow c = 2$
  - 忽略: 无 (所有属性均涉及重要状态)
- 相异性:  $d(P1, P2) = \frac{2 + 2}{1 + 2 + 2} = \frac{4}{5} = 0.8$

P1 vs P3

- 症状向量: P3: [F=1, C=1, H=0, N=1, W=0]
- 匹配统计：
  - $A \cap B$  : 发烧 (F)、恶心 (N)  $\rightarrow a = 2$
  - P1=1且P3=0: 头痛 (H)  $\rightarrow b = 1$
  - P1=0且P3=1: 咳嗽 (C)  $\rightarrow c = 1$
  - 忽略: 乏力 (W) (均为0)
- 相异性:  $d(P1, P3) = \frac{1 + 1}{2 + 1 + 1} = \frac{2}{4} = 0.5$

P2 vs P4

- 症状向量: P4: [F=0, C=0, H=1, N=0, W=1]
- 匹配统计：
  - $A \cap B$  : 头痛 (H)、乏力 (W)  $\rightarrow a = 2$
  - P2=1且P4=0: 咳嗽 (C)  $\rightarrow b = 1$
  - P2=0且P4=1: 无  $\rightarrow c = 0$
  - 忽略: 发烧 (F)、恶心 (N) (均为0)
- 相异性:  $d(P2, P4) = \frac{1 + 0}{2 + 1 + 0} = \frac{1}{3} \approx 0.33$

4. 相异性矩阵

|  |    |    |    |    |
|--|----|----|----|----|
|  | P1 | P2 | P3 | P4 |
|--|----|----|----|----|

|    |     |      |      |      |
|----|-----|------|------|------|
| P1 | 0   | 0.8  | 0.5  | 1.0  |
| P2 | 0.8 | 0    | 0.75 | 0.33 |
| P3 | 0.5 | 0.75 | 0    | 0.8  |
| P4 | 1.0 | 0.33 | 0.8  | 0    |

- **P1与P4**：无共同症状 → 相异性=1.0（完全不相似）。
- **P2与P4**：共享头痛和乏力 → 相异性较低（0.33）。

|      |                      |                   |
|------|----------------------|-------------------|
| 属性类型 | 相异性度量方法              | 关键特点              |
| 标称   | 不匹配属性数 / 总属性数        | 无序，所有不匹配同等对待      |
| 二元   | Jaccard系数（非对称时忽略0-0） | 区分对称/非对称，关注重要状态匹配 |

P48 闵可夫斯基距离：四个距离的定义 例2.21 2.22

1. 欧几里得距离（Euclidean Distance）

欧几里得距离是最常见的距离度量方式，本质是两点之间的“直线距离”。

$$d(x,y)=\sqrt{\sum_{i=1}^n(x_i-y_i)^2}$$

例子：两个点 A=(1,2)，B=(4,6)

$$d=\sqrt{(4-1)^2+(6-2)^2}=\sqrt{9+16}=\sqrt{25}=5$$

2. 曼哈顿距离（Manhattan Distance）

又称“城市街区距离”，只能沿坐标轴方向走。

$$d(x,y)=\sum_{i=1}^n|x_i-y_i|$$

例子：点 A=(1,2)，B=(4,6)

$$d=|4-1|+|6-2|=3+4=7$$

3. 闵可夫斯基距离（Minkowski Distance）

欧几里得距离和曼哈顿距离的推广形式，通过一个参数 pp 控制。

$$d(x,y)=\left(\sum_{i=1}^n|x_i-y_i|^p\right)^{1/p}$$

- 当 p=1 就是曼哈顿距离；

- 当  $p = 2$  就是欧几里得距离；
- 当  $p \rightarrow \infty$  就是切比雪夫距离。

例子：用  $p = 3$  来算点  $A=(1,2)$ ， $B=(4,6)$  的距离：

$$d = (|4 - 1|^3 + |6 - 2|^3)^{1/3} = (27 + 64)^{1/3} = 91^{1/3} \approx 4.481$$

4. 上确界距离（切比雪夫距离 / Chebyshev Distance）

又称  $L^\infty$  范数，闵可夫斯基距离在  $p \rightarrow \infty$  时的极限形式。

$$d(x, y) = \max_i |x_i - y_i|$$

例子：点  $A=(1,2)$ ， $B=(4,6)$

$$d = \max(|4 - 1|, |6 - 2|) = \max(3, 4) = 4$$

以下是关于 序数型属性间的相异性 和 混合类型属性间的相异性 计算的详细说明与具体示例：

5. 序数型属性间的相异性计算

序数型属性特点

- 值之间存在明确的顺序关系，但差值无明确数学意义（如教育程度：小学<初中<高中<大学）。
- 需先将序数转换为连续的数值（如通过归一化排名），再计算距离。

计算步骤

- 映射序数值到排名：将序数属性的等级转换为数值（如小学=1，初中=2，高中=3，大学=4）。
- 归一化排名：将排名映射到[0,1]区间：

$$z_i = \frac{r_i - 1}{M - 1}, \text{ 其中 } M \text{ 为最大等级数}$$

- 计算相异性：使用数值型距离（上面提到的任意一种距离度量计算）计算归一化后的值。

示例

| 患者 | 疼痛等级（无/轻/中/重） | 恢复阶段（初期/中期/后期） |
|----|---------------|----------------|
| P1 | 中             | 中期             |
| P2 | 重             | 后期             |

步骤：

- 映射排名：
  - 疼痛等级：无=1，轻=2，中=3，重=4 → P1=3，P2=4
  - 恢复阶段：初期=1，中期=2，后期=3 → P1=2，P2=3
- 归一化：

- 疼痛等级 (M=4) : P1:  $z_1 = \frac{3-1}{4-1} = 0.67$  ; P2:  $= \frac{4-1}{4-1} = 1.0$
- 恢复阶段 (M=3) : P1:  $z_1 = \frac{2-1}{3-1} = 0.5$  ; P2:  $z_2 = \frac{3-1}{3-1} = 1.0$

3. 计算相异性 (以曼哈顿距离为例) :  $d(P1,P2) = |0.67 - 1.0| + |0.5 - 1.0| = 0.33 + 0.5 = 0.83$

## 6. 混合类型属性间的相异性计算

### 混合类型属性特点

- 数据包含多种类型属性 (如数值型、标称型、序数型、二元型) 。
- 需分别计算各属性的相异性后加权组合。

### 通用计算步骤

#### 1. 分类型处理:

- 数值型: 归一化后直接计算距离 (如欧几里得) 。
- 标称型: 不匹配时为1, 匹配时为0。
- 序数型: 转换为排名并归一化。
- 二元型: 使用Jaccard系数 (非对称时忽略0-0) 。

#### 2. 加权求和:

$$d(i, j) = \frac{\sum_{k=1}^m w_k \cdot d_k(i, j)}{\sum_{k=1}^m w_k}$$

- $w_k$  : 第k个属性的权重 (可设为1或根据重要性调整) 。
- $d_k(i, j)$  : 第k个属性的相异性。

### 示例

| 患者 | 年龄 (数值) | 性别 (标称) | 血压等级 (序数: 低/中/高) | 糖尿病 (二元: 是=1) |
|----|---------|---------|------------------|---------------|
| P1 | 35      | 男       | 中                | 0             |
| P2 | 50      | 女       | 高                | 1             |

### 步骤:

#### 1. 分类型处理:

- 年龄 (数值型)
  - 归一化 (假设年龄范围20-80) : P1:  $\frac{35-20}{80-20} = 0.25$  ; P2:  $\frac{50-20}{80-20} = 0.5$
  - 相异性:  $|0.25 - 0.5| = 0.25$

- **性别**（标称型）
  - 男≠女 → d = 1
- **血压等级**（序数型）
  - 低=1，中=2，高=3 → P1=2, P2=3
  - 归一化:  $z_{P1} = \frac{2-1}{3-1} = 0.5$ ,  $z_{P2} = 1.0$
  - 相异性:  $|0.5 - 1.0| = 0.5$
- **糖尿病**（非对称二元型）:
  - P1=0, P2=1 → 忽略“0-0”匹配, 相异性=1

2. **加权求和**（假设权重均为1）  $d(P1, P2) = \frac{0.25 + 1 + 0.5 + 1}{4} = \frac{2.75}{4} \approx 0.69$

## P52 余弦相似性 例2.23

余弦相似性通过计算两个向量的夹角余弦值来衡量它们的相似性，忽略向量长度（模）的差异，专注于方向一致性。

- **范围**:  $[-1, 1]$ , 1表示完全相同, 0表示无关, -1表示完全相反。
- **适用场景**: 文本相似度、推荐系统、图像特征匹配等。

对于两个n维向量  $\mathbf{A} = (a_1, a_2, \dots, a_n)$  和  $\mathbf{B} = (b_1, b_2, \dots, b_n)$ ，余弦相似性为：

$$\text{cosine}(\mathbf{A}, \mathbf{B}) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \sqrt{\sum_{i=1}^n b_i^2}}$$

- $\mathbf{A} \cdot \mathbf{B}$  是向量点积。
- $\|\mathbf{A}\|$  和  $\|\mathbf{B}\|$  是向量的模（欧几里得范数）。

### 示例：简单数值向量

计算向量  $\mathbf{A} = [1, 2, 3]$  和  $\mathbf{B} = [4, 5, 6]$  的余弦相似性：

1. **计算点积**:  $\mathbf{A} \cdot \mathbf{B} = 1 \times 4 + 2 \times 5 + 3 \times 6 = 4 + 10 + 18 = 32$

2. **计算向量模**:

$$\|\mathbf{A}\| = \sqrt{1^2 + 2^2 + 3^2} = \sqrt{14} \approx 3.74$$

$$\|\mathbf{B}\| = \sqrt{4^2 + 5^2 + 6^2} = \sqrt{77} \approx 8.77$$

3. **余弦相似性**:

$$\text{cosine}(\mathbf{A}, \mathbf{B}) = \frac{32}{3.74 \times 8.77} \approx \frac{32}{32.8} \approx 0.976$$

**解释**: 两向量方向高度相似（接近1）。

### 关键特性与注意事项



1. **长度不变性**：余弦相似性只关注向量方向，与向量长度无关。例如， $\mathbf{A} = [1, 1]$  和  $\mathbf{B} = [100, 100]$  的相似性为1。
2. **稀疏数据适用性**：适合处理高维稀疏数据（如文本TF-IDF向量），能有效忽略共同缺失的特征（0值）。
3. **与欧氏距离的区别**：欧氏距离受向量长度影响，余弦相似性不受影响。当向量长度归一化后，欧氏距离  $d = \sqrt{2(1 - \text{cosine})}$
4. **负值处理**：若向量包含负值（如情感分析中的词嵌入），余弦相似性可捕捉反向关系（相似性为-1）。

## 第三章

### P59 分箱 图3.2

分箱是一种数据预处理技术，用于将连续或有序的数值数据划分为若干个区间（称为“箱”或“桶”），然后对每个箱中的数据进行处理（如光滑、离散化）。其核心思想是通过考察数据的局部近邻值，减少噪声或微小波动的影响，从而揭示数据的整体趋势。

#### 分箱的核心步骤

1. **排序数据**：将原始数据按值从小到大排序。示例：原始价格数据：[4, 8, 15, 21, 21, 24, 25, 28, 34] 排序后：[4, 8, 15, 21, 21, 24, 25, 28, 34]（已有序）。
2. **划分箱 (Bin)**：
  - **等频分箱**：每个箱包含相同数量的数据点（如示例中每箱3个值）。
  - **等宽分箱**：每个箱的数值范围固定（如每箱宽度为10美元）。
  - **示例（等频分箱）** 箱1：[4, 8, 15] 箱2：[21, 21, 24] 箱3：[25, 28, 34]
3. **光滑处理（可选）**：
  - **箱均值光滑**：用箱内均值替换所有值。箱1均值 =  $(4+8+15)/3 = 9$  → 替换为 [9, 9, 9]
  - **箱中位数光滑**：用箱内中位数替换。箱1中位数 = 8 → 替换为 [8, 8, 8]
  - **箱边界光滑**：用箱内最小值或最大值替换（选择最近的边界）。箱1边界为 4 和 15：4 替换为 4（最近边界是自身），8 离 4 更近 → 替换为 4，15 替换为 15 → 结果 [4, 4, 15]

#### 分箱的用途

1. **数据光滑 (Smoothing)**：减少噪声或微小波动，保留整体趋势（如图3.2中的价格光滑）。
2. **离散化 (Discretization)**：将连续数据转换为分类标签（如将年龄分为“青年”“中年”“老年”）。
3. **异常值处理**：将极端值归入边界箱，降低其对分析的影响。

分箱方法的对比

| 方法    | 描述           | 示例（箱1: [4,8,15]）  | 适用场景          |
|-------|--------------|-------------------|---------------|
| 等频分箱  | 每个箱数据量相同     | 箱1: 4,8,15（固定3个值） | 数据分布不均匀时      |
| 等宽分箱  | 每个箱数值范围相同    | 箱1: 0-10 → 4,8    | 数据分布均匀时       |
| 箱均值光滑 | 用均值替换箱内所有值   | 替换为 9,9,9         | 保留整体水平，忽略局部波动 |
| 箱边界光滑 | 用最近的最小/最大值替换 | 替换为 4,4,15        | 突出数据边界特征      |

P63 例3.1 卡方分布 公式3.1 3.2

卡方统计量：

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- $O_{ij}$  是观测频数（实际值）。
- $E_{ij}$  是期望频数（在变量独立的假设下计算），计算公式为：

$$E_{ij} = \frac{(\text{行合计}_i) \times (\text{列合计}_j)}{\text{总样本量}}$$

- 自由度  $df = (r - 1)(c - 1)$ ，其中r是行数，c是列数。

举例：研究性别（男、女）与是否喜欢某种产品（喜欢、不喜欢）是否独立。数据如下：

|    |     |     |     |
|----|-----|-----|-----|
|    | 喜欢  | 不喜欢 | 合计  |
| 男  | 50  | 30  | 80  |
| 女  | 60  | 60  | 120 |
| 合计 | 110 | 90  | 200 |

1. 计算期望频数  $E_{ij}$ ：

- 男性喜欢的期望：  $E_{11} = \frac{80 \times 110}{200} = 44$
- 男性不喜欢的期望：  $E_{12} = \frac{80 \times 90}{200} = 36$
- 女性喜欢的期望：  $E_{21} = \frac{120 \times 110}{200} = 66$
- 女性不喜欢的期望：  $E_{22} = \frac{120 \times 90}{200} = 54$

2. 计算卡方值：

$$\chi^2 = \frac{(50 - 44)^2}{44} + \frac{(30 - 36)^2}{36} + \frac{(60 - 66)^2}{66} + \frac{(60 - 54)^2}{54} \approx 2.34$$

3. 查卡方分布表（ $df = 1$ ），若卡方值大于临界值，则拒绝独立性假设。

P65 协方差 例3.2

协方差用于衡量 **两个随机变量** 之间的线性关系方向：

- **协方差 > 0**：两变量呈正相关（一个增大，另一个也倾向于增大）。
- **协方差 < 0**：两变量呈负相关（一个增大，另一个倾向于减小）。
- **协方差 = 0**：两变量无线性关系（但不一定独立）。

协方差公式

$$\text{Cov}(A, B) = E[(A - \mu_A)(B - \mu_B)] = \frac{1}{n} \sum_{i=1}^n (a_i - \mu_A)(b_i - \mu_B)$$

**计算示例：**假设我们有以下5 名学生的数学（X）和物理（Y）成绩：

| 学生 | 数学（X） | 物理（Y） |
|----|-------|-------|
| A  | 80    | 70    |
| B  | 90    | 85    |
| C  | 70    | 65    |
| D  | 60    | 55    |
| E  | 85    | 75    |

步骤 1：计算均值

$$\bar{X} = \frac{80 + 90 + 70 + 60 + 85}{5} = 77$$
$$\bar{Y} = \frac{70 + 85 + 65 + 55 + 75}{5} = 70$$

步骤 2：计算每个观测值的离差

| 学生 | $X_i - \bar{X}$ | $Y_i - \bar{Y}$ | 乘积  |
|----|-----------------|-----------------|-----|
| A  | $80 - 77 = +3$  | $70 - 70 = 0$   | 0   |
| B  | $90 - 77 = +13$ | $85 - 70 = +15$ | 195 |
| C  | $70 - 77 = -7$  | $65 - 70 = -5$  | 35  |
|    |                 |                 |     |

|   |               |               |     |
|---|---------------|---------------|-----|
| D | 60 - 77 = -17 | 55 - 70 = -15 | 255 |
| E | 85 - 77 = +8  | 75 - 70 = +5  | 40  |

步骤 3：计算协方差

$$\text{Cov}(X, Y) = \frac{0 + 195 + 35 + 255 + 40}{5 - 1} = \frac{525}{4} = 131.25$$

结论：协方差131.25 > 0，说明数学和物理成绩呈正相关（数学成绩高的学生，物理成绩也倾向于高）。

P75 最小-最大规范化，z分数规范化 例3.4 3.5

1. 最小-最大规范化（Min-Max Normalization）

将数据线性变换到指定范围（通常为 [0, 1]）。

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \times (\text{new\_max} - \text{new\_min}) + \text{new\_min}$$

- 默认范围 [0, 1] (new\_min=0, new\_max=1)：

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

举例：

原始数据： [10, 20, 30, 40] ，规范化到 [0, 1]：

- $X_{\min} = 10, X_{\max} = 40$
- 规范化后： $\frac{10 - 10}{40 - 10} = 0$ ； $\frac{20 - 10}{40 - 10} = 0.333$ ； $\frac{30 - 10}{40 - 10} = 0.666$ ； $\frac{40 - 10}{40 - 10} = 1$
- 结果： [0, 0.333, 0.666, 1]

2. Z分数规范化（Z-Score Normalization）

将数据转换为均值为 0、标准差为 1 的分布。

$$X_{\text{z-score}} = \frac{X - \mu}{\sigma}$$

- $\mu$ ：均值
- $\sigma$ ：标准差（样本标准差用s，分母为n）

举例：

原始数据： [10, 20, 30, 40]

- 均值  $\mu = \frac{10 + 20 + 30 + 40}{4} = 25$
- 标准差  $\sigma$ ： $\sigma = \sqrt{\frac{(10 - 25)^2 + (20 - 25)^2 + (30 - 25)^2 + (40 - 25)^2}{4}} = \sqrt{\frac{500}{4}} = 11.18$

- Z分数:  $\frac{10 - 25}{11.18} = -1.34$ ;  $\frac{20 - 25}{11.18} = -0.45$ ;  $\frac{30 - 25}{11.18} = 0.45$ ;  $\frac{40 - 25}{11.18} = 1.34$
- 结果: `[-1.34, -0.45, 0.45, 1.34]`

P76 小数定标 例3.6

**作用：**通过移动小数点将数据缩放到[-1, 1]或更小的范围，适用于数值较大的数据集。

**核心思想：**找到最小的整数d，使得所有数据除以  $10^d$  后落在目标范围内。

$$X_{\text{scaled}} = \frac{X}{10^d}$$

- d是满足  $\max(|X_{\text{scaled}}|) < 1$  的最小整数（例如  $d = \lfloor \log_{10}(\max(|X|)) \rfloor + 1$ ）。

计算步骤

1. 找到数据中的 **绝对值最大值**  $X_{\text{max}}$ 。
2. 计算最小的d使得  $\frac{|X_{\text{max}}|}{10^d} < 1$ :  $d = \lfloor \log_{10}(|X_{\text{max}}|) \rfloor + 1$
3. 对所有数据除以  $10^d$ 。

**原始数据：** `[1250, -320, 780, 4100]`

1. 绝对值最大值  $X_{\text{max}} = 4100$ 。
2. 计算d:  $\log_{10}(4100) \approx 3.61 \implies d = 3 + 1 = 4$ （因为  $4100/10^4 = 0.41 < 1$ ）
3. 对所有数据除以  $10^4 = 10000$ ：

$$\frac{1250}{10000} = 0.125, \quad \frac{-320}{10000} = -0.032, \quad \frac{780}{10000} = 0.078, \quad \frac{4100}{10000} = 0.41$$

**规范化结果：** `[0.125, -0.032, 0.078, 0.41]`（所有值在[-1, 1]内）。

| 方法       | 特点           | 适用场景            | 注意事项                   |
|----------|--------------|-----------------|------------------------|
| 小数定标     | 简单，保留数据正负和分布 | 大范围数值（如金额、科学计数） | 小数定标仅缩放数值，不改变分布形状      |
| 最小-最大规范化 | 固定范围（如 [0,1] | 需要明确边界的场景（如图像）  | 对离群值敏感（极端值会压缩正常数据的范围）  |
| Z分数规范化   | 均值为0，标准差为1   | 数据分布未知或存在离群值    | 适合数据符合正态分布或需要保留分布形状的场景 |

Kmeans算法的处理流程

假设有一组9位足球运动员，他们中每个人都在这一赛季进了一定数量的球（假设在3-30之间），然后我们要将他们分成3组。

|  |  |  |  |  |  |  |  |  |
|--|--|--|--|--|--|--|--|--|
|  |  |  |  |  |  |  |  |  |
|--|--|--|--|--|--|--|--|--|

|     |   |    |    |   |   |    |    |   |    |
|-----|---|----|----|---|---|----|----|---|----|
| 运动员 | A | B  | C  | D | E | F  | G  | H | I  |
| 进球数 | 5 | 20 | 11 | 5 | 9 | 19 | 30 | 3 | 15 |

步骤1：初始化

随机选择3个初始簇中心（这里选A、C、E的进球数作为中心）：

- 初始中心： 簇1中心： A（5） 簇2中心： C（11） 簇3中心： E（9）

步骤2：分配数据点到最近簇

计算所有球员与3个簇中心的欧氏距离（即进球数差的绝对值），并分配到最近的簇：

| 球员 | 进球数 | 到A-5的距离 | 到C-11的距离 | 到E-9的距离 | 所属簇 |
|----|-----|---------|----------|---------|-----|
| A  | 5   | 0       | 6        | 4       | 簇1  |
| B  | 20  | 15      | 9        | 11      | 簇2  |
| C  | 11  | 6       | 0        | 2       | 簇3  |
| D  | 5   | 0       | 6        | 4       | 簇1  |
| E  | 9   | 4       | 2        | 0       | 簇3  |
| F  | 19  | 14      | 8        | 10      | 簇2  |
| G  | 30  | 25      | 19       | 21      | 簇2  |
| H  | 3   | 2       | 8        | 6       | 簇1  |
| I  | 15  | 10      | 4        | 6       | 簇2  |

第一次聚类结果：

- 簇1： {A(5), D(5), H(3)}
- 簇2： {B(20), F(19), G(30), I(15)}
- 簇3： {C(11), E(9)}

步骤3：更新簇中心

计算每个簇的新中心（均值）：

- 簇1新中心：  $(5 + 5 + 3)/3 = 4.3$  （簇1进球数的平均值）
- 簇2新中心：  $(20 + 19 + 30 + 15)/4 = 21$  （簇2进球数的平均值）
- 簇3新中心：  $(11 + 9)/2 = 10$  （簇3进球数的平均值）

## 步骤4：计算准则函数（SSE）

计算每个点到簇中心的距离平方和（Sum of Squared Errors, SSE）：

- 簇1：  $(5 - 4.3)^2 + (5 - 4.3)^2 + (3 - 4.3)^2 = 0.49 + 0.49 + 1.69 = 2.67$
- 簇2：  $(20 - 21)^2 + (19 - 21)^2 + (30 - 21)^2 + (15 - 21)^2 = 1 + 4 + 81 + 36 = 122$
- 簇3：  $(11 - 10)^2 + (9 - 10)^2 = 1 + 1 = 2$

总SSE：  $2.67 + 122 + 2 = 126.67$

## 步骤5：迭代优化

重复步骤2-4，直到簇中心不再变化或SSE收敛：

- 第二次迭代**：用新中心（4.3, 21, 10）重新分配球员，更新簇中心和SSE。若SSE减少不明显或中心不变，则停止。

## 关键点总结

- 初始化**：随机选择初始中心，可能影响结果（可用K-means++优化）。
- 分配与更新**：交替进行“分配数据点”和“更新簇中心”。
- 停止条件**：簇中心不变或SSE变化小于阈值。
- 局限性**：对离群值敏感，需手动指定K值。

# 第六章

## P161 apriori算法 生成关联规则 例6.4

| 交易ID | 购买商品           |
|------|----------------|
| T1   | 牛奶, 面包, 鸡蛋     |
| T2   | 牛奶, 面包, 啤酒     |
| T3   | 牛奶, 面包, 鸡蛋, 啤酒 |
| T4   | 面包, 啤酒         |
| T5   | 牛奶, 鸡蛋         |

### 1. 设置最小支持度阈值

首先我们需要设置一个最小支持度(minimum support)阈值，这里设为40%(即至少出现在2笔交易中)。

### 2. 找出频繁1项集(L1)

扫描所有交易，计算每个单项的支持度：

- 牛奶: 出现在T1,T2,T3,T5 → 支持度=4/5=80%
- 面包: 出现在T1,T2,T3,T4 → 支持度=4/5=80%
- 鸡蛋: 出现在T1,T3,T5 → 支持度=3/5=60%
- 啤酒: 出现在T2,T3,T4 → 支持度=3/5=60%

所有单项的支持度都 $\geq 40\%$ ，所以频繁1项集L1为：{牛奶}, {面包}, {鸡蛋}, {啤酒}

### 3. 生成候选2项集(C2)并找出频繁2项集(L2)

通过连接L1中的项集生成候选2项集，然后计算支持度：

候选2项集C2：{牛奶,面包}, {牛奶,鸡蛋}, {牛奶,啤酒}, {面包,鸡蛋}, {面包,啤酒}, {鸡蛋,啤酒}

计算支持度：

- {牛奶,面包}: T1,T2,T3 → 3/5=60%
- {牛奶,鸡蛋}: T1,T3,T5 → 3/5=60%
- {牛奶,啤酒}: T2,T3 → 2/5=40%
- {面包,鸡蛋}: T1,T3 → 2/5=40%
- {面包,啤酒}: T2,T3,T4 → 3/5=60%
- {鸡蛋,啤酒}: T3 → 1/5=20% (低于阈值，丢弃)

频繁2项集L2：

{牛奶,面包}, {牛奶,鸡蛋}, {牛奶,啤酒}, {面包,鸡蛋}, {面包,啤酒}

### 4. 生成候选3项集(C3)并找出频繁3项集(L3)

通过连接L2中的项集（可以从L1中生成，然后通过L2舍弃不合理的）生成候选3项集(使用Apriori性质：任何非频繁项集的超集也是非频繁的)：

可能的候选：

1. {牛奶,面包,鸡蛋}: 子集{牛奶,面包}, {牛奶,鸡蛋}, {面包,鸡蛋}都在L2中
2. {牛奶,面包,啤酒}: 子集{牛奶,面包}, {牛奶,啤酒}, {面包,啤酒}都在L2中
3. {牛奶,鸡蛋,啤酒}: 子集{鸡蛋,啤酒}不在L2中 → 不生成
4. {面包,鸡蛋,啤酒}: 子集{鸡蛋,啤酒}不在L2中 → 不生成

所以C3 = {牛奶,面包,鸡蛋}, {牛奶,面包,啤酒}

计算支持度：

- {牛奶,面包,鸡蛋}: T1,T3 → 2/5=40%
- {牛奶,面包,啤酒}: T2,T3 → 2/5=40%



两者都满足最小支持度，所以 $L3 = \{\text{牛奶,面包,鸡蛋}\}, \{\text{牛奶,面包,啤酒}\}$

### 5. 生成候选4项集(C4)

尝试生成4项集： $\{\text{牛奶,面包,鸡蛋,啤酒}\}$ 的子集： $\{\text{面包,鸡蛋,啤酒}\}$ 不在 $L3$ 中  $\rightarrow$  不生成

因此没有候选4项集，算法终止。

### 生成关联规则

从频繁项集可以生成关联规则。例如从频繁3项集 $\{\text{牛奶,面包,鸡蛋}\}$ ：

非空子集： $\{\text{牛奶,面包}\}, \{\text{牛奶,鸡蛋}\}, \{\text{面包,鸡蛋}\}, \{\text{牛奶}\}, \{\text{面包}\}, \{\text{鸡蛋}\}$

可能的规则：

- 1. 牛奶,面包  $\rightarrow$  鸡蛋
- 2. 牛奶,鸡蛋  $\rightarrow$  面包
- 3. 面包,鸡蛋  $\rightarrow$  牛奶
- 4. 牛奶  $\rightarrow$  面包,鸡蛋
- 5. 面包  $\rightarrow$  牛奶,鸡蛋
- 6. 鸡蛋  $\rightarrow$  牛奶,面包

计算置信度(confidence)：规则 $X \rightarrow Y$ 的置信度 =  $\text{support}(X \cup Y) / \text{support}(X)$

例如规则"牛奶,面包  $\rightarrow$  鸡蛋": 置信度 =  $\text{support}(\{\text{牛奶,面包,鸡蛋}\}) / \text{support}(\{\text{牛奶,面包}\}) = 40\% / 60\% \approx 66.7\%$

假设我们设置最小置信度为50%，那么这条规则就是有效的。

### P166 FP-growth算法

| 交易ID | 购买商品           |
|------|----------------|
| T1   | 牛奶, 面包, 鸡蛋     |
| T2   | 牛奶, 面包, 啤酒     |
| T3   | 牛奶, 面包, 鸡蛋, 啤酒 |
| T4   | 面包, 啤酒         |
| T5   | 牛奶, 鸡蛋         |

同样设置最小支持度阈值为40%（即至少出现在2笔交易中）。

#### 1. 第一次扫描数据库：统计项目频率

计算每个项目的支持度（与Apriori相同）：所有项目都满足最小支持度。

- 牛奶: 4次 (T1,T2,T3,T5)
- 面包: 4次 (T1,T2,T3,T4)
- 鸡蛋: 3次 (T1,T3,T5)
- 啤酒: 3次 (T2,T3,T4)

## 2. 按频率降序排序项目

根据支持度计数降序排列项目：**面包(4), 牛奶(4), 鸡蛋(3), 啤酒(3)**。备注：当多个项目的支持度计数相同时（如本例中的面包和牛奶都是4），它们的排序顺序确实会影响最终构建的FP树结构，但不会影响最终挖掘出的频繁项集结果。



## 3. 第二次扫描数据库：构建FP树

按照排序后的顺序处理每条交易：

**事务处理过程：**

1. T1: 牛奶,面包,鸡蛋 → 排序后: 面包,牛奶,鸡蛋
  - 根→面包→牛奶→鸡蛋
2. T2: 牛奶,面包,啤酒 → 排序后: 面包,牛奶,啤酒
  - 面包节点已存在，计数+1
  - 面包→牛奶节点已存在，计数+1
  - 牛奶→啤酒（新节点）
3. T3: 牛奶,面包,鸡蛋,啤酒 → 排序后: 面包,牛奶,鸡蛋,啤酒
  - 面包→牛奶→鸡蛋路径已存在（计数+1）
  - 然后从鸡蛋→啤酒（新节点）
4. T4: 面包,啤酒 → 排序后: 面包,啤酒
  - 面包节点计数+1
  - 面包→啤酒（新节点）
5. T5: 牛奶,鸡蛋 → 排序后: 牛奶,鸡蛋
  - 牛奶不在面包下（因为排序后面包在前），所以创建新路径：根→牛奶→鸡蛋

**构建的FP树结构：**



头表（Header Table）结构：

| 项目 | 支持度计数 | 节点链接               |
|----|-------|--------------------|
| 面包 | 4     | →面包节点1             |
| 牛奶 | 4     | →牛奶节点1→牛奶节点2       |
| 鸡蛋 | 3     | →鸡蛋节点1→鸡蛋节点2       |
| 啤酒 | 3     | →啤酒节点1→啤酒节点2→啤酒节点3 |

#### 4. 从FP树挖掘频繁模式

采用自底向上的方式（从后往前看），从频率最低的项目开始（啤酒）：

##### 1. 啤酒的条件模式基：

- 路径1: 面包→牛奶→鸡蛋→啤酒 (计数:1)
- 路径2: 面包→牛奶→啤酒 (计数:1)
- 路径3: 面包→啤酒 (计数:1)

啤酒的条件FP树（只包含面包,牛奶,鸡蛋）：

- 面包:3 (出现在3条路径中)
- 牛奶:2

- 鸡蛋:1 (由于最小支持度为2, 鸡蛋被剪枝)

啤酒的频繁模式:

- {啤酒,面包} (支持度3)
- {啤酒,牛奶} (支持度2)
- {啤酒,面包,牛奶} (支持度2)

## 2. 鸡蛋的条件模式基:

- 路径1: 面包→牛奶→鸡蛋 (计数:2)
- 路径2: 牛奶→鸡蛋 (计数:1)

鸡蛋的条件FP树: 所有项目都满足最小支持度。

- 牛奶:3 (2+1)
- 面包:2

鸡蛋的频繁模式:

- {鸡蛋,牛奶} (支持度3)
- {鸡蛋,面包} (支持度2)
- {鸡蛋,面包,牛奶} (支持度2)

## 3. 牛奶的条件模式基:

- 路径1: 面包→牛奶 (计数:3)
- 路径2: 牛奶 (计数:1)

牛奶的条件FP树: 面包:3

牛奶的频繁模式: {牛奶,面包} (支持度3)

## 4. 面包的条件模式基:

面包是单一路径, 没有前缀路径

面包的频繁模式: {面包} (支持度4)

## 5. 合并所有频繁模式

最终所有频繁项集 (支持度 $\geq 2$ ):

1-项集: {面包}(4), {牛奶}(4), {鸡蛋}(3), {啤酒}(3)

2-项集: {面包,牛奶}(3), {面包,鸡蛋}(2), {面包,啤酒}(3), {牛奶,鸡蛋}(3), {牛奶,啤酒}(2)

3-项集: {面包,牛奶,鸡蛋}(2), {面包,牛奶,啤酒}(2)

## FP-Growth vs Apriori比较

- 效率: FP-Growth通常比Apriori更快, 因为它只需要扫描数据库两次, 而Apriori需要多次扫描

- 2. 内存：FP-Growth需要内存存储FP树，对于密集数据集可能占用较多内存
- 3. 候选集：FP-Growth不生成候选集，直接构建条件模式基

P165 散列 图6.5

这个散列技术是Apriori算法的一种优化方法，主要用于高效地压缩候选2项集（即 $C_2$ ），减少需要检查的候选项集数量。

核心思想

- 1. 目的：在从频繁1项集( $L_1$ )生成候选2项集( $C_2$ )时，提前过滤掉不可能成为频繁项集的候选项
- 2. 方法：使用散列函数将事务中的所有2项集映射到散列表的不同桶中，通过桶计数快速筛选

具体步骤解析

- 1. 扫描数据库时同时构建散列表：
  - 当扫描数据库识别频繁1项集( $L_1$ )时，对每个事务中所有可能的2项集进行散列
  - 例如事务包含{11,12,13}，则生成2项集{11,12}, {11,13}, {12,13}并散列到对应桶
- 2. 散列过程：使用散列函数 $h(x,y) = (10 \times (x的序) + y的序) \bmod 7$
- 3. 桶计数机制：
  - 每个桶维护一个计数器
  - 当一个2项集被散列到某个桶时，该桶计数加1
  - 示例中桶2、5、6的计数为4，说明这些桶中的项集出现较多
- 4. 筛选候选2项集：
  - 设置最小支持度阈值（示例中为3）
  - 只保留桶计数 $\geq 3$ 的桶中的项集作为候选2项集( $C_2$ )
  - 示例中桶0、1、3、4被淘汰（计数=2 < 3）保留桶2、5、6中的项集：{12,13}, {11,12}, {11,13}

|       |          |          |          |          |          |          |          |
|-------|----------|----------|----------|----------|----------|----------|----------|
| $H_2$ |          |          |          |          |          |          |          |
| 桶地址   | 0        | 1        | 2        | 3        | 4        | 5        | 6        |
| 桶计数   | 2        | 2        | 4        | 2        | 2        | 4        | 4        |
| 桶内容   | {11, 14} | {11, 15} | {12, 13} | {12, 14} | {12, 15} | {11, 12} | {11, 13} |
|       | {13, 15} | {11, 15} | {12, 13} | {12, 14} | {12, 15} | {11, 12} | {11, 13} |
|       |          |          | {12, 13} |          |          | {11, 12} | {11, 13} |
|       |          |          | {12, 13} |          |          | {11, 12} | {11, 13} |

为什么这种技术有效

- 1. **假阴性不会发生**：如果一个2项集是频繁的，它必然会被散列到一个高频桶中。不会错误地淘汰真正的频繁项集
- 2. **可能有假阳性**：一个桶计数高可能是因为其中某个项集频繁，而其他不频繁。所以还需要对保留的项集进行精确支持度计数
- 3. **显著减少候选项**：示例中7个桶淘汰了4个，减少了57%的候选。特别是当k=2时效果最好，因为2项集数量是组合数增长最快的阶段

这种技术在Apriori算法的早期阶段能：大幅减少内存消耗（存储更少的候选项）；减少后续扫描数据库时的计算；特别适合处理包含大量2项集的数据集。这是Apriori算法多种优化技术中非常有效的一种，尤其适用于稀疏数据集。

P167 图6.7 FP树 要会画（结合FP算法）




图 6.7 存放压缩的频繁模式信息的 FP 树

P169 垂直数据格式找频繁模式

垂直数据格式（Vertical Data Format）是关联规则挖掘中一种高效的数据表示方法，它将传统的水平格式（事务-项目）转换为项目-事务的形式。最小支持度=2，即40%

| 交易ID | 购买商品           |
|------|----------------|
| T1   | 牛奶, 面包, 鸡蛋     |
| T2   | 牛奶, 面包, 啤酒     |
| T3   | 牛奶, 面包, 鸡蛋, 啤酒 |
| T4   | 面包, 啤酒         |

|    |        |
|----|--------|
| T5 | 牛奶, 鸡蛋 |
|----|--------|

转换为垂直数据格式，将每个项目与包含它的事务ID列表关联：

```
代码块
1 牛奶: {T1, T2, T3, T5}
2 面包: {T1, T2, T3, T4}
3 鸡蛋: {T1, T3, T5}
4 啤酒: {T2, T3, T4}
```

1. 频繁2-项集

计算每个项目的支持度（事务集的大小）：所有单项都满足最小支持度≥2

- 牛奶:  $|\{T1,T2,T3,T5\}| = 4$
- 面包:  $|\{T1,T2,T3,T4\}| = 4$
- 鸡蛋:  $|\{T1,T3,T5\}| = 3$
- 啤酒:  $|\{T2,T3,T4\}| = 3$

2. 频繁2-项集

通过求事务集交集来计算2-项集的支持度：

- $\{牛奶,面包\} = \{T1,T2,T3,T5\} \cap \{T1,T2,T3,T4\} = \{T1,T2,T3\} \rightarrow 支持度=3$
- $\{牛奶,鸡蛋\} = \{T1,T2,T3,T5\} \cap \{T1,T3,T5\} = \{T1,T3,T5\} \rightarrow 支持度=3$
- $\{牛奶,啤酒\} = \{T1,T2,T3,T5\} \cap \{T2,T3,T4\} = \{T2,T3\} \rightarrow 支持度=2$
- $\{面包,鸡蛋\} = \{T1,T2,T3,T4\} \cap \{T1,T3,T5\} = \{T1,T3\} \rightarrow 支持度=2$
- $\{面包,啤酒\} = \{T1,T2,T3,T4\} \cap \{T2,T3,T4\} = \{T2,T3,T4\} \rightarrow 支持度=3$
- $\{鸡蛋,啤酒\} = \{T1,T3,T5\} \cap \{T2,T3,T4\} = \{T3\} \rightarrow 支持度=1 \text{（不满足）}$

所有支持度≥2的2-项集都是频繁的。

3. 频繁3-项集

基于频繁2-项集生成候选3-项集并计算支持度：

- $\{牛奶,面包,鸡蛋\} = \{T1,T2,T3\} \cap \{T1,T3,T5\} = \{T1,T3\} \rightarrow 支持度=2$
- $\{牛奶,面包,啤酒\} = \{T1,T2,T3\} \cap \{T2,T3,T4\} = \{T2,T3\} \rightarrow 支持度=2$
- $\{牛奶,鸡蛋,啤酒\} = \{T2,T3\} \cap \{T1,T3,T5\} = \{T3\} \rightarrow 支持度=1 \text{（不满足）}$
- $\{面包,鸡蛋,啤酒\} = \{T2,T3,T4\} \cap \{T1,T3\} = \{T3\} \rightarrow 支持度=1 \text{（不满足）}$

支持度≥2的3-项集： $\{牛奶,面包,鸡蛋\}, \{牛奶,面包,啤酒\}$

4. 频繁4-项集

{牛奶,面包,鸡蛋,啤酒} = {T1,T3} ∩ {T2,T3} = {T3} → 支持度=1（不满足）没有频繁4-项集。

垂直格式的优势

- 1. 高效支持度计算：通过集合交集运算直接得到支持度，无需扫描整个数据库
- 2. 减少I/O开销：只需存储项目及其对应的事务ID集合
- 3. 适合稀疏数据：当数据稀疏时，事务ID列表存储效率高
- 4. 易于并行化：不同项集的支持度计算可以独立进行

P172 例6.8 lift计算

提升度(Lift)是关联规则挖掘中用于衡量规则实际效果的重要指标，它表示规则中前项和后项的实际相关性相比于它们独立发生时的强度。

| 交易ID | 购买商品           |
|------|----------------|
| T1   | 牛奶, 面包, 鸡蛋     |
| T2   | 牛奶, 面包, 啤酒     |
| T3   | 牛奶, 面包, 鸡蛋, 啤酒 |
| T4   | 面包, 啤酒         |
| T5   | 牛奶, 鸡蛋         |

提升度(Lift)的公式为：

$$\text{Lift}(X \rightarrow Y) = \frac{\text{Confidence}(X \rightarrow Y)}{\text{Support}(Y)} = \frac{\text{Support}(X \cup Y)}{\text{Support}(X) \times \text{Support}(Y)}$$

- Lift = 1：X和Y独立，没有相关性
- Lift > 1：X和Y正相关
- Lift < 1：X和Y负相关

示例1：规则"牛奶 → 面包"

- 1. 计算各部分支持度：
  - Support(牛奶) = 4/5 = 0.8
  - Support(面包) = 4/5 = 0.8
  - Support(牛奶 ∪ 面包) = 3/5 = 0.6 (同时购买牛奶和面包的交易有T1,T2,T3)



2. 计算置信度：Confidence(牛奶→面包) = Support(牛奶 ∪ 面包)/Support(牛奶) = 0.6/0.8 = 0.75

3. 计算提升度：Lift = 0.6 / (0.8 × 0.8) = 0.6 / 0.64 ≈ 0.9375

解释：提升度≈0.94 < 1，表示购买牛奶和购买面包之间存在轻微的负相关关系。

示例2：规则"面包 → 啤酒"

1. 计算各部分支持度：

- Support(面包) = 4/5 = 0.8
- Support(啤酒) = 3/5 = 0.6
- Support(面包 ∪ 啤酒) = 3/5 = 0.6 (T2,T3,T4)

2. 计算置信度：Confidence(面包→啤酒) = 0.6/0.8 = 0.75

3. 计算提升度：Lift = 0.6 / (0.8 × 0.6) = 0.6 / 0.48 = 1.25

解释：提升度=1.25 > 1，表示购买面包和购买啤酒之间存在正相关关系。

| 提升度范围     | 含义     | 商业意义           |
|-----------|--------|----------------|
| Lift > 1  | X和Y正相关 | X的出现提高了Y出现的可能性 |
| Lift = 1  | X和Y独立  | X对Y的出现没有影响     |
| Lift < 1  | X和Y负相关 | X的出现降低了Y出现的可能性 |
| Lift ≈ 1  | 相关性很弱  | 规则可能没有实际意义     |
| Lift >> 1 | 强正相关   | 强关联，适合做推荐或捆绑销售 |

为什么提升度比置信度更好？

1. "啤酒 → 面包"：置信度=3/3=1.0；Lift = 0.6/(0.6×0.8)=1.25

2. "面包 → 啤酒"：置信度=3/4=0.75；Lift = 0.6/(0.8×0.6)=1.25

虽然两个规则的置信度不同，但提升度相同，因为它们反映的是相同的相关性。提升度消除了项目流行度的影响，能更客观地衡量相关性。

P172-173 全置信度，最大置信度，kulczynski和余弦

| 交易ID | 购买商品       |
|------|------------|
| T1   | 牛奶, 面包, 鸡蛋 |
| T2   | 牛奶, 面包, 啤酒 |
|      |            |

|    |                |
|----|----------------|
| T3 | 牛奶, 面包, 鸡蛋, 啤酒 |
| T4 | 面包, 啤酒         |
| T5 | 牛奶, 鸡蛋         |

总交易数 (T) : 5 最小支持度 (min\_sup) : 2 (40%)

1. 全置信度 (All-Confidence)

定义: 规则  $X \rightarrow Y$  的全置信度是  $X \cup Y$  的支持度与X和Y的最大支持度的比值。

$$\text{All-Confidence}(X \rightarrow Y) = \frac{\text{Support}(X \cup Y)}{\max(\text{Support}(X), \text{Support}(Y))}$$

特点:

- 取值在 [0, 1] 之间, 值越大表示 X 和 Y 同时出现的概率越高。
- 对 **低频项 (支持度低)** 敏感, 避免过度偏向高频项。

示例计算:

计算规则 {牛奶, 面包}  $\rightarrow$  {鸡蛋} (即  $X = \{\text{牛奶, 面包}\}, Y = \{\text{鸡蛋}\}$ ) :

- $\text{Support}(X \cup Y) = \text{Support}(\{\text{牛奶, 面包, 鸡蛋}\}) = 2/5 = 0.4$  (T1, T3)
- $\text{Support}(X) = \text{Support}(\{\text{牛奶, 面包}\}) = 3/5 = 0.6$  (T1, T2, T3)
- $\text{Support}(Y) = \text{Support}(\{\text{鸡蛋}\}) = 3/5 = 0.6$  (T1, T3, T5)
- $\max(\text{Support}(X), \text{Support}(Y)) = \max(0.6, 0.6) = 0.6$
- $\text{All-Confidence} = \frac{0.4}{0.6} \approx 0.666$

解释: 全置信度为 0.666, 表示 {牛奶, 面包} 和 {鸡蛋} 同时出现的概率是它们单独出现概率最大值的 66.6%, 说明有一定的关联性。

2. 最大置信度 (Max-Confidence)

定义: 规则  $X \rightarrow Y$  的最大置信度是  $X \cup Y$  的支持度与X或Y的最小支持度的比值。

$$\text{Max-Confidence}(X \rightarrow Y) = \frac{\text{Support}(X \cup Y)}{\min(\text{Support}(X), \text{Support}(Y))}$$

特点:

- 取值在[0, 1]之间, 值越大表示X和Y的关联性越强。
- 比 **全置信度** 更宽松, 适用于 **高频项** 的关联分析。

示例计算:

计算规则 {面包}  $\rightarrow$  {啤酒} (即  $X = \{\text{面包}\}, Y = \{\text{啤酒}\}$ ) :

- $\text{Support}(X \cup Y) = \text{Support}(\{\text{面包, 啤酒}\}) = 3/5 = 0.6$  (T2, T3, T4)

2.  $\text{Support}(X) = \text{Support}(\{\text{面包}\}) = 4/5 = 0.8$
3.  $\text{Support}(Y) = \text{Support}(\{\text{啤酒}\}) = 3/5 = 0.6$
4.  $\min(\text{Support}(X), \text{Support}(Y)) = \min(0.8, 0.6) = 0.6$
5.  $\text{Max-Confidence} = \frac{0.6}{0.6} = 1.0$

**解释：** 最大置信度为 1.0，表示 {面包} 和 {啤酒} 同时出现的概率等于它们单独出现概率的最小值，说明 {面包} 出现时 {啤酒} 必然出现（在这个数据集中）。

### 3. Kulczynski (库尔辛斯基系数)

**定义：** Kulczynski 是全置信度和最大置信度的平均值，用于平衡两者的偏差。

$$\text{Kulczynski}(X \rightarrow Y) = \frac{\text{All-Confidence} + \text{Max-Confidence}}{2}$$

**特点：**

- 取值在  $[0, 1]$  之间，综合了 **全置信度（偏向低频）** 和 **最大置信度（偏向高频）**。
- 适用于 **平衡高频和低频项** 的关联分析。

**示例计算：**

继续使用 {面包}  $\rightarrow$  {啤酒} 的例子：

1.  $\text{All-Confidence} = \frac{0.6}{\max(0.8, 0.6)} = \frac{0.6}{0.8} = 0.75$
2.  $\text{Max-Confidence} = 1.0$ （前面计算过）
3.  $\text{Kulczynski} = \frac{0.75 + 1.0}{2} = 0.875$

**解释：** Kulczynski 值为 0.875，表示 {面包} 和 {啤酒} 的关联性较强，且比单独使用全置信度或最大置信度更稳健。

### 4. 余弦 (Cosine) 相似度

**定义：** 余弦相似度衡量 X 和 Y 的共同出现程度，类似于向量夹角。

$$\text{Cosine}(X \rightarrow Y) = \frac{\text{Support}(X \cup Y)}{\sqrt{\text{Support}(X) \times \text{Support}(Y)}}$$

**特点：**

- 取值在  $[0, 1]$  之间，值越大表示 X 和 Y 的共现性越强。
- 类似于提升度 (Lift)，但取值范围更稳定。

**示例计算：**

计算 {牛奶}  $\rightarrow$  {鸡蛋}：

1.  $\text{Support}(X \cup Y) = \text{Support}(\{\text{牛奶}, \text{鸡蛋}\}) = 3/5 = 0.6$  (T1, T3, T5)
2.  $\text{Support}(X) = \text{Support}(\{\text{牛奶}\}) = 4/5 = 0.8$

3.  $\text{Support}(Y) = \text{Support}(\{\text{鸡蛋}\}) = 3/5 = 0.6$

4.  $\text{Cosine} = \frac{0.6}{\sqrt{0.8 \times 0.6}} = \frac{0.6}{\sqrt{0.48}} \approx \frac{0.6}{0.693} \approx 0.866$

解释：余弦相似度为 0.866，表示 {牛奶} 和 {鸡蛋} 的共现性很强，接近 1 说明它们经常一起购买。

对比总结

| 指标         | 特点              | 适用场景               |
|------------|-----------------|--------------------|
| 全置信度       | 偏向低频项，避免高频项主导   | 分析 低频但强关联 的规则      |
| 最大置信度      | 偏向高频项，适用于强关联规则  | 分析 高频项 的必然性        |
| Kulczynski | 平衡全置信度和最大置信度，稳健 | 综合评估 高频和低频 关联      |
| 余弦相似度      | 类似提升度，但取值范围更稳定  | 衡量 **共现性**，适用于推荐系统 |

- 1. 如果关注低频但强关联的规则（如小众商品组合）→ 使用全置信度。
- 2. 如果关注高频项的必然性（如啤酒和面包）→ 使用最大置信度。
- 3. 如果需要平衡高低频项 → 使用Kulczynski。
- 4. 如果要做推荐系统（衡量共现性）→ 使用余弦相似度。

第七章

P188 定义7.1 定义7.2 零事务问题 例7.5

零事务问题是指在关联规则挖掘中，那些不包含任何被考察项集的事务对相关性度量产生的影响。

定义7.1零事务问题

定义7.1判断负相关的标准是：如果 $\text{sup}(X \cup Y) < \text{sup}(X) \times \text{sup}(Y)$ ，则认为X和Y是负相关的。

- 1. 200个事务的情况：
  - $\text{sup}(A \cup B) = 1/200 = 0.005$
  - $\text{sup}(A) \times \text{sup}(B) = (100/200) \times (100/200) = 0.25$
  - $0.005 < 0.25 \rightarrow$  正确判断为负相关
- 2. 1,000,000个事务的情况：
  - $\text{sup}(A \cup B) = 1/1,000,000 = 0.000001$
  - $\text{sup}(A) \times \text{sup}(B) = (100/1,000,000) \times (100/1,000,000) = 0.00000001$
  - $0.000001 > 0.00000001 \rightarrow$  错误判断为正相关

**问题本质：**当零事务(既不包含A也不包含B的事务)数量大幅增加时， $\sup(A) \times \sup(B)$ 会变得极小，导致原本负相关的关系被错误判断为正相关。

## 定义7.2零事务问题

定义7.2判断负相关的标准是： $\sup(A \cup \neg B) \times \sup(\neg A \cup B) \gg \sup(A \cup B) \times \sup(\neg A \cup \neg B)$

### 例题7.5分析：

#### 1. 200个事务的情况：

- $\sup(A \cup \neg B) = 99/200$
- $\sup(\neg A \cup B) = 99/200$
- $\sup(A \cup B) = 1/200$
- $\sup(\neg A \cup \neg B) = 199/200$
- 左边 =  $(99/200) \times (99/200) \approx 0.245$
- 右边 =  $(1/200) \times (199/200) \approx 0.005$
- $0.245 \gg 0.005 \rightarrow$  正确判断为负相关

#### 2. 1,000,000个事务的情况：

- $\sup(A \cup \neg B) = 99/1,000,000$
- $\sup(\neg A \cup B) = 99/1,000,000$
- $\sup(A \cup B) = 1/1,000,000$
- $\sup(\neg A \cup \neg B) \approx 1,000,000/1,000,000 = 1$
- 左边  $\approx (99/10^6) \times (99/10^6) \approx 9.8 \times 10^{-11}$
- 右边  $\approx (1/10^6) \times 1 \approx 1 \times 10^{-6}$
- $9.8 \times 10^{-11} \ll 1 \times 10^{-6} \rightarrow$  错误判断为正相关

**问题本质：**当零事务数量增加时， $\sup(\neg A \cup \neg B)$ 趋近于1，导致右边项变得很大，从而反转了相关性的判断。

## 零不变性的重要性

零不变性是指相关性度量不应该受到零事务数量的影响。一个好的相关性度量应该：

1. 只考虑实际包含被考察项集的事务
2. 不受不相关事务数量的影响
3. 在项集出现频率不变的情况下，即使总事务数变化，判断结果也应保持一致

解决方案的方向，如文中提到的，基于Kulczynski度量(条件概率的平均值)的定义7.3可能是更好的选择，因为它：

1. 关注项集之间的条件概率

2. 不受零事务数量的直接影响
3. 更符合人类对相关性的直观理解

## P189 定义7.3 例7.6 基于Kulczynski度量的负相关模式

定义7.3判断负相关的标准是：

1. 首先要求X和Y都是频繁项集： $\sup(X) \geq \min\_sup$ ,  $\sup(Y) \geq \min\_sup$
2. 然后计算条件概率的平均值： $(P(X|Y) + P(Y|X))/2$
3. 如果这个平均值小于负模式阈值 $\epsilon$ ，则判定为负相关

其中： $P(X|Y) = \sup(X \cup Y) / \sup(Y)$ ， $P(Y|X) = \sup(X \cup Y) / \sup(X)$ ， $\epsilon$ 是用户设定的负模式阈值(如例子中的0.02)

### 例题7.6分析

1. 情况1：200个事务
  - $\sup(A) = \sup(B) = 100/200 = 0.5$
  - $\sup(A \cup B) = 1/200 = 0.005$
  - 计算： $P(B|A) = \sup(A \cup B) / \sup(A) = 0.005/0.5 = 0.01$ ， $P(A|B) = \sup(A \cup B) / \sup(B) = 0.005/0.5 = 0.01$ ，平均值 =  $(0.01 + 0.01)/2 = 0.01$
  - 比较： $0.01 < 0.02(\epsilon) \rightarrow$  判定为负相关
2. 情况2：1,000,000个事务
  - $\sup(A) = \sup(B) = 100/1,000,000 = 0.0001$
  - $\sup(A \cup B) = 1/1,000,000 = 0.000001$
  - 计算： $P(B|A) = 0.000001/0.0001 = 0.01$ ， $P(A|B) = 0.000001/0.0001 = 0.01$ ，平均值 =  $(0.01 + 0.01)/2 = 0.01$
  - 比较： $0.01 < 0.02 \rightarrow$  依然判定为负相关
3. 情况3：10,000个事务的特殊案例
  - $\sup(A) = 1000/10000 = 0.1$
  - $\sup(B) = 10/10000 = 0.001$
  - $\sup(A \cup B) = 10/10000 = 0.001$  (因为每次B出现都伴随A)
  - 计算： $P(B|A) = 0.001/0.1 = 0.01$ ， $P(A|B) = 0.001/0.001 = 1$ ，平均值 =  $(0.01 + 1)/2 = 0.505$
  - 比较： $0.505 > 0.02 \rightarrow$  判定为正相关

### 定义7.3的优势

1. **零不变性**：无论零事务(既不包含A也不包含B的事务)数量如何变化，只要A和B的出现频率和共现频率比例不变，判断结果就保持一致。

2. **对称性**：同时考虑了 $P(X|Y)$ 和 $P(Y|X)$ ，避免了单一方向条件概率的偏差。
3. **直观合理性**：当A和B很少同时出现( $P(X|Y)$ 和 $P(Y|X)$ 都很小)时，判定为负相关。当其中一个项集的出现几乎总是伴随着另一个( $P(A|B) \approx 1$ )时，即使另一个条件概率很小，整体也会判定为正相关
4. **抗干扰性**：不受不相关事务数量的影响，只关注实际包含被考察项集的事务。

实际应用指导

1. 选择合适的min\_sup：确保分析的项集确实具有统计意义
2. 设置合理的 $\epsilon$ 值：需要根据具体领域知识确定多大的条件概率平均值算作"负相关"
3. 解释结果时：低平均值表示两个项集很少同时出现；高平均值表示至少在一个方向上，项集的出现会促进另一个项集的出现

第八章

P217 信息增益计算 例8.1

衡量使用某个特征进行分割后，信息不确定性减少的程度。

1. 信息熵(Entropy)

信息熵是度量样本集合纯度的指标，表示随机变量的不确定性。计算公式为：

$$H(D) = - \sum_{i=1}^n p_i \log_2 p_i$$

- D是数据集；n是类别数量； $p_i$  是第  $i$  类样本在数据集D中所占比例

2. 条件熵(Conditional Entropy)

条件熵表示在已知特征A的条件下，数据集D 的不确定性。计算公式为：

$$H(D|A) = \sum_{j=1}^v \frac{|D_j|}{|D|} H(D_j)$$

- v是特征A的取值个数， $D_j$  是特征A取第j个值的子集

3. 信息增益(Information Gain)

信息增益表示由于特征A而使得数据集D的不确定性减少的程度：

$$IG(D, A) = H(D) - H(D|A)$$

4. 计算步骤详解

|             |          |              |           |           |
|-------------|----------|--------------|-----------|-----------|
| 天气(Outlook) | 温度(Temp) | 湿度(Humidity) | 刮风(Windy) | 打网球(Play) |
|             |          |              |           |           |

|          |      |        |       |     |
|----------|------|--------|-------|-----|
| Sunny    | Hot  | High   | False | No  |
| Sunny    | Hot  | High   | True  | No  |
| Overcast | Hot  | High   | False | Yes |
| Rainy    | Mild | High   | False | Yes |
| Rainy    | Cool | Normal | False | Yes |
| Rainy    | Cool | Normal | True  | No  |
| Overcast | Cool | Normal | True  | Yes |
| Sunny    | Mild | High   | False | No  |
| Sunny    | Cool | Normal | False | Yes |
| Rainy    | Mild | Normal | False | Yes |
| Sunny    | Mild | Normal | True  | Yes |
| Overcast | Mild | High   | True  | Yes |
| Overcast | Hot  | Normal | False | Yes |
| Rainy    | Mild | High   | True  | No  |

步骤1：计算整体熵H(D)

- 1. 统计类别分布：Yes: 9个，No: 5个，总计: 14个
- 2. 计算各类别概率：P(Yes) = 9/14, P(No) = 5/14
- 3. 计算整体熵： $H(D) = - \left( \frac{9}{14} \log_2 \frac{9}{14} + \frac{5}{14} \log_2 \frac{5}{14} \right) \approx 0.940$

步骤2：计算各特征的条件熵：以"Outlook"特征为例：

- 1. 统计特征取值分布：
  - Sunny: 5个(Yes:2, No:3)
  - Overcast: 4个(Yes:4, No:0)
  - Rainy: 5个(Yes:3, No:2)
- 2. 计算各取值的熵：
  - H(Sunny) = - (2/5 log<sub>2</sub>(2/5) + 3/5 log<sub>2</sub>(3/5)) ≈ 0.971
  - H(Overcast) = 0 (因为只有Yes)
  - H(Rainy) = - (3/5 log<sub>2</sub>(3/5) + 2/5 log<sub>2</sub>(2/5)) ≈ 0.971



3. 计算条件熵:  $H(D|Outlook) = \frac{5}{14} \times 0.971 + \frac{4}{14} \times 0 + \frac{5}{14} \times 0.971 \approx 0.694$

### 步骤3: 计算信息增益

$$IG(D, Outlook) = H(D) - H(D|Outlook) = 0.940 - 0.694 = 0.246$$

### 步骤4: 计算其他特征的信息增益

$$IG(D, Temperature) \approx 0.029; IG(D, Humidity) \approx 0.152; IG(D, Windy) \approx 0.048$$

### 信息增益的特点

1. **优点:** 计算简单, 易于理解; 能够有效衡量特征对分类的贡献程度
2. **缺点:** 倾向于选择取值较多的特征(因为这类特征容易将数据划分得更"纯"); 不考虑特征之间的相关性

## P220 增益率 例8.2 基尼指数 例8.3

### 1. 增益率(Gain Ratio)

增益率是C4.5决策树算法中用于特征选择的指标, 它解决了信息增益对多值特征的偏好问题。

增益率 = 信息增益 / 固有价值(Intrinsic Value)

$$GainRatio(D, A) = \frac{IG(D, A)}{IV(A)}$$

其中固有价值:

$$IV(A) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \log_2 \frac{|D_j|}{|D|}$$

### 计算示例 (继续使用Outlook特征)

已知信息增益  $IG(D, Outlook) = 0.246$ , 计算固有价值  $IV(Outlook)$ :

1. Outlook取值分布: Sunny: 5/14; Overcast: 4/14; Rainy: 5/14
2. 计算:  $IV(Outlook) = - \left( \frac{5}{14} \log_2 \frac{5}{14} + \frac{4}{14} \log_2 \frac{4}{14} + \frac{5}{14} \log_2 \frac{5}{14} \right) \approx 1.577$
3. 计算增益率:  $GainRatio(D, Outlook) = \frac{0.246}{1.577} \approx 0.156$

同样方法计算其他特征:

- Temperature的IV  $\approx 1.557$ , GainRatio  $\approx 0.029/1.557 \approx 0.019$
- Humidity的IV  $\approx 1.000$ , GainRatio  $\approx 0.152/1.000 \approx 0.152$
- Windy的IV  $\approx 0.985$ , GainRatio  $\approx 0.048/0.985 \approx 0.049$

**增益率特点:** 解决了信息增益对多值特征的偏好, 当IV(A)很小时(特征取值很少), 可能会放大噪声, 因此C4.5通常先选择信息增益高于平均值的特征, 再从中选增益率最大的

## 2. 基尼指数(Gini Index)

基尼指数是CART决策树算法中用于特征选择的指标，表示从数据集中随机抽取两个样本，其类别标记不一致的概率。

数据集D的基尼指数：

$$Gini(D) = 1 - \sum_{i=1}^n p_i^2$$

特征A条件下的基尼指数：

$$Gini(D, A) = \sum_{j=1}^v \frac{|D_j|}{|D|} Gini(D_j)$$

### 计算整体基尼指数

1. 类别分布：Yes: 9/14; No: 5/14

2. 计算：  $Gini(D) = 1 - \left[ \left( \frac{9}{14} \right)^2 + \left( \frac{5}{14} \right)^2 \right] \approx 0.459$

### 计算Outlook特征的基尼指数

1. 各取值分布：

◦ Sunny: 5个(Yes:2, No:3),  $Gini(\text{Sunny}) = 1 - [(2/5)^2 + (3/5)^2] = 0.48$

◦ Overcast: 4个(Yes:4, No:0),  $Gini(\text{Overcast}) = 1 - [(4/4)^2 + (0/4)^2] = 0$

◦ Rainy: 5个(Yes:3, No:2),  $Gini(\text{Rainy}) = 1 - [(3/5)^2 + (2/5)^2] = 0.48$

2. 计算条件基尼指数：  $Gini(D, \text{Outlook}) = \frac{5}{14} \times 0.48 + \frac{4}{14} \times 0 + \frac{5}{14} \times 0.48 \approx 0.343$

3. 基尼指数减少量：  $\Delta Gini = Gini(D) - Gini(D, \text{Outlook}) = 0.459 - 0.343 = 0.116$

### 其他特征的基尼指数

• Temperature:  $Gini \approx 0.439, \Delta Gini \approx 0.020$

• Humidity:  $Gini \approx 0.367, \Delta Gini \approx 0.092$

• Windy:  $Gini \approx 0.429, \Delta Gini \approx 0.030$

**基尼指数特点：**计算比信息熵更简单(不需要对数运算)，对类别分布更加敏感，CART树使用基尼指数作为分裂标准

## P229 例8.4 高斯朴素贝叶斯

### 1. 高斯朴素贝叶斯基本原理

高斯朴素贝叶斯假设每个特征在每个类别下服从高斯（正态）分布，且特征之间条件独立。分类决策公式：

$$P(y|x_1, x_2, \dots, x_n) \propto P(y) \prod_{i=1}^n P(x_i|y)$$

- $y$  是类别（男性或女性）
- $x_i$  是特征值
- $P(y)$  是类别的先验概率
- $P(x_i|y)$  是特征在给定类别下的条件概率

## 2. 高斯概率密度函数

对于连续特征，使用高斯概率密度函数：

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_{y,i}^2}} \exp\left(-\frac{(x_i - \mu_{y,i})^2}{2\sigma_{y,i}^2}\right)$$

- $\mu_{y,i}$  是类别  $y$  下第  $i$  个特征的均值
- $\sigma_{y,i}^2$  是类别  $y$  下第  $i$  个特征的方差

## 3. 具体计算步骤

假设我们要分类一个新样本，其特征值为：身高= $h$ ，体重= $w$ ，脚长= $f$ 。

### • 计算类先验概率

假设男女比例相等（如果没有额外信息）：

$$P(\text{男性}) = P(\text{女性}) = 0.5$$

### • 计算条件概率

对于男性类别：

$$\begin{aligned} P(h|\text{男性}) &= \frac{1}{\sqrt{2\pi \times 32.250}} \exp\left(-\frac{(h - 178.250)^2}{2 \times 32.250}\right) \\ P(w|\text{男性}) &= \frac{1}{\sqrt{2\pi \times 25.470}} \exp\left(-\frac{(w - 79.925)^2}{2 \times 25.470}\right) \\ P(f|\text{男性}) &= \frac{1}{\sqrt{2\pi \times 5.983}} \exp\left(-\frac{(f - 28.575)^2}{2 \times 5.983}\right) \end{aligned}$$

对于女性类别：

$$P(h|\text{女性}) = \frac{1}{\sqrt{2\pi \times 92.670}} \exp\left(-\frac{(h - 165.000)^2}{2 \times 92.670}\right)$$

$$P(w|\text{女性}) = \frac{1}{\sqrt{2\pi \times 114.040}} \exp\left(-\frac{(w - 60.100)^2}{2 \times 114.040}\right)$$

$$P(f|\text{女性}) = \frac{1}{\sqrt{2\pi \times 10.923}} \exp\left(-\frac{(f - 19.050)^2}{2 \times 10.923}\right)$$

#### • 计算后验概率

对于男性：

$$P(\text{男性}|h, w, f) \propto P(\text{男性}) \times P(h|\text{男性}) \times P(w|\text{男性}) \times P(f|\text{男性})$$

对于女性：

$$P(\text{女性}|h, w, f) \propto P(\text{女性}) \times P(h|\text{女性}) \times P(w|\text{女性}) \times P(f|\text{女性})$$

#### • 分类决策

比较两个后验概率，选择较大的那个作为预测类别：

$$\text{预测类别} = \arg \max_{y \in \{\text{男性}, \text{女性}\}} P(y|h, w, f)$$

### 4. 实际计算示例

假设有一个新样本：身高=170cm，体重=65kg，脚长=25cm

#### • 计算男性类别的联合概率

计算每个特征的概率密度：

$$1. \text{ 身高: } P(170|\text{男性}) = \frac{1}{\sqrt{2\pi \times 32.250}} \exp\left(-\frac{(170 - 178.250)^2}{2 \times 32.250}\right) \approx 0.029$$

$$2. \text{ 体重: } P(65|\text{男性}) = \frac{1}{\sqrt{2\pi \times 25.470}} \exp\left(-\frac{(65 - 79.925)^2}{2 \times 25.470}\right) \approx 0.002$$

$$3. \text{ 脚长: } P(25|\text{男性}) = \frac{1}{\sqrt{2\pi \times 5.983}} \exp\left(-\frac{(25 - 28.575)^2}{2 \times 5.983}\right) \approx 0.191$$

$$\text{联合概率: } P(\text{男性}|170, 65, 25) \propto 0.5 \times 0.029 \times 0.002 \times 0.191 \approx 5.53 \times 10^{-6}$$

#### • 计算女性类别的联合概率

$$1. \text{ 身高: } P(170|\text{女性}) = \frac{1}{\sqrt{2\pi \times 92.670}} \exp\left(-\frac{(170 - 165.000)^2}{2 \times 92.670}\right) \approx 0.041$$

$$2. \text{ 体重: } P(65|\text{女性}) = \frac{1}{\sqrt{2\pi \times 114.040}} \exp\left(-\frac{(65 - 60.100)^2}{2 \times 114.040}\right) \approx 0.033$$

$$3. \text{ 脚长: } P(25|\text{女性}) = \frac{1}{\sqrt{2\pi \times 10.923}} \exp\left(-\frac{(25 - 19.050)^2}{2 \times 10.923}\right) \approx 0.013$$

$$\text{联合概率: } P(\text{女性}|170, 65, 25) \propto 0.5 \times 0.041 \times 0.033 \times 0.013 \approx 8.79 \times 10^{-6}$$

## • 比较结果

女性类别的联合概率 ( $8.79 \times 10^{-4}$ ) 大于男性类别的联合概率 ( $5.53 \times 10^{-4}$ )，因此预测该样本为女性。

## P230 例8.5 拉普拉斯校准避免零概率问题

当训练数据中某个特征值在特定类别下从未出现时，传统概率估计会导致零概率。这会导致整个后验概率乘积为零，影响分类结果。通过给所有可能的特征值计数加一个小的常数（通常为1），确保没有零概率出现：

$$P_{\text{smoothed}}(x_i|y) = \frac{\text{count}(x_i, y) + \alpha}{\text{count}(y) + \alpha \times n_i}$$

- $\alpha$ ：平滑参数（通常取1）
- $n_i$ ：特征 $x_i$ 的可能取值数量

## 实施步骤

1. 统计原始计数，对于每个类别  $y$  和特征值  $x_i$ ，统计训练集中该类别下该特征值出现的次数  $N_{y,x_i}$ ，统计该类别总样本数  $N_y$
2. 应用拉普拉斯校准：对每个概率估计进行平滑处理：（这里假设  $\alpha = 1$ ）

$$P(x_i|y) = \frac{N_{y,x_i} + 1}{N_y + n_i}$$

3. 计算分母调整：注意分母需要加上  $n_i$ （不是  $n_i \times \alpha$ ，因为  $\alpha = 1$ ）

## 具体案例

原始数据（buys\_computer=yes类，1000个样本）：

- income=low: 0个；income=medium: 990个；income=high: 10个

## 传统估计：

- $P(\text{low}|\text{yes}) = 0/1000 = 0$ （零概率问题）； $P(\text{medium}|\text{yes}) = 990/1000 = 0.990$ ； $P(\text{high}|\text{yes}) = 10/1000 = 0.010$

## 拉普拉斯校准后 ( $\alpha=1$ )：

- 可能取值数量  $n_i=3$  (low, medium, high)；分母调整： $1000 + 3 = 1003$

## 校准后概率：

- $P(\text{low}|\text{yes}) = (0+1)/1003 \approx 0.001$ ； $P(\text{medium}|\text{yes}) = (990+1)/1003 \approx 0.988$ ； $P(\text{high}|\text{yes}) = (10+1)/1003 \approx 0.011$

## P231 IF-THEN规则分类 例8.6

IF-THEN规则分类是数据挖掘中一种基于规则的分类方法，它使用"如果-那么"形式的规则来预测新数据的类别。

一个IF-THEN规则的形式为：

代码块

1 IF 条件 THEN 结论

其中：

- 条件部分(IF部分)是属性测试的合取(AND连接)
- 结论部分(THEN部分)是类预测

例题中的规则R1(P230)是：

代码块

1 IF age = youth AND student = yes THEN buys\_computer = yes

1. 覆盖率(Coverage)

覆盖率衡量规则能够覆盖多少训练数据：

$$coverage(R) = \frac{\text{满足规则条件的元组数}}{\text{总元组数}}$$

在例8.6中：总元组数：14，满足R1的元组数：2。所以  $coverage(R1) = 2/14 \approx 14.28\%$

2. 准确率(Accuracy)

准确率衡量规则在覆盖的元组中预测正确的比例：

$$accuracy(R) = \frac{\text{正确分类的元组数}}{\text{满足规则条件的元组数}}$$

在例8.6中：满足R1的元组数：2，这2个元组都被正确分类。所以  $accuracy(R1) = 2/2 = 100\%$

规则分类过程

当对新元组X进行分类时：

1. 找出所有被X触发的规则(即X满足规则的条件部分)
2. 如果有多个规则被触发：选择最高优先级的规则(通常基于准确率、覆盖率或其他标准)，或者使用投票机制
3. 如果没有规则被触发：使用默认类(通常是训练数据中最常见的类)

在例子中，元组X = (age=youth, income=medium, student=yes, credit\_rating=fair)触发了R1规则，因此根据R1预测buys\_computer=yes。

P232 由决策树提取规则 例8.7

沿着从根结点到树中每个树叶结点的路径，下图决策树可以转换成IF-THEN分类规则：

- R1: IF age = youth AND student = no THEN buys\_computer = no
- R2: IF age = youth AND student = yes THEN buys\_computer = yes
- R3: IF age = middle\_aged THEN buys\_computer = yes
- R4: IF age = senior AND credit\_rating = excellent THEN buys\_computer = yes
- R5: IF age = senior AND credit rating = fair THEN buys computer = no




图 8.2 概念 *buys\_computer* 的决策树，指出 AllElectronics 的顾客是否可能购买计算机。每个内部（非树叶）结点表示一个属性上的测试，每个树叶结点代表一个类（*buys\_computer* = yes，或 *buys\_computer* = no）

## P237 真正例，真负例，假正例，真假负例

在分类问题中，我们常用混淆矩阵(Confusion Matrix)来评估模型性能，其中涉及四个关键概念：

### 1. 基本定义

假设我们有一个二分类问题，类别为"正类"(Positive)和"负类"(Negative)：

| 术语  | 简称                  | 含义           | 解释                       |
|-----|---------------------|--------------|--------------------------|
| 真正例 | TP (True Positive)  | 模型正确预测为正类的样本 | 实际为正类，预测也为正类             |
| 真负例 | TN (True Negative)  | 模型正确预测为负类的样本 | 实际为负类，预测也为负类             |
| 假正例 | FP (False Positive) | 模型错误预测为正类的样本 | 实际为负类，但预测为正类 (Type I错误)  |
| 假负例 | FN (False Negative) | 模型错误预测为负类的样本 | 实际为正类，但预测为负类 (Type II错误) |

### 2. 可视化表示

| 代码块 | 实际值 |
|-----|-----|
| 1   |     |



|   |              |          |          |
|---|--------------|----------|----------|
| 2 |              | Positive | Negative |
| 3 | 预测值 Positive | TP       | FP       |
| 4 | Negative     | FN       | TN       |

### 3. 具体示例

以"计算机购买预测"为例(正类="购买", 负类="不购买"):

- **真正例(TP)**: 顾客实际购买了计算机, 模型也预测"购买"
- **真负例(TN)**: 顾客实际没购买计算机, 模型预测"不购买"
- **假正例(FP)**: 顾客实际没购买计算机, 但模型预测"购买"(误报)
- **假负例(FN)**: 顾客实际购买了计算机, 但模型预测"不购买"(漏报)

### 4. 指标

从这四个基本量可以计算出多种评估指标:

1. **准确率(Accuracy)** =  $(TP+TN)/(TP+TN+FP+FN)$  - 所有预测正确的比例
2. **精确率(Precision)** =  $TP/(TP+FP)$  - 预测为正类的样本中实际为正类的比例
3. **召回率(Recall)** =  $TP/(TP+FN)$  - 实际正类被正确预测的比例
4. **F1分数** =  $2 \times (Precision \times Recall)/(Precision+Recall)$  - 精确率和召回率的调和平均

## P239 灵敏性和特效性 例8.9 精度和召回率 例8.10

### 1. 灵敏度/召回率(Sensitivity/Recall)

- **公式:**  $Recall = TP / (TP + FN) = TP / P$
- **解释:** 实际为正类的样本中被正确识别为正类的比例
- **应用场景:** 当漏检正类的代价很高时 (如疾病诊断)
- **示例:** 在100个癌症患者中, 模型检测出90个 → 召回率=90%

### 2. 特效性(Specificity)

- **公式:**  $Specificity = TN / (TN + FP) = TN / N$
- **解释:** 实际为负类的样本中被正确识别为负类的比例
- **应用场景:** 当误报负类的代价很高时 (如垃圾邮件过滤)
- **示例:** 在100个健康人中, 模型正确排除95个 → 特效性=95%

### 3. 精度(Precision)

- **公式:**  $Precision = TP / (TP + FP)$
- **解释:** 预测为正类的样本中实际为正类的比例




- **应用场景:** 当误报正类的代价很高时（如法律判决）
- **示例:** 模型预测100个癌症病例中，80个是真的 → 精度=80%

## P244 ROC曲线画图

ROC曲线（Receiver Operating Characteristic curve）是一种展示分类模型在所有分类阈值下性能表现的图形工具。它以：

- X轴：假正例率  $FPR = FP / (FP + TN) = FP / N$
- Y轴：真正例率  $TPR = TP / (TP + FN) = TP / P$

| 元组编号 | 类 | 概率   | TP | FP | TN | FN | TPR | FPR |
|------|---|------|----|----|----|----|-----|-----|
| 1    | P | 0.90 | 1  | 0  | 5  | 4  | 0.2 | 0   |
| 2    | P | 0.80 | 2  | 0  | 5  | 3  | 0.4 | 0   |
| 3    | N | 0.70 | 2  | 1  | 4  | 3  | 0.4 | 0.2 |
| 4    | P | 0.60 | 3  | 1  | 4  | 2  | 0.6 | 0.2 |
| 5    | P | 0.55 | 4  | 1  | 4  | 1  | 0.8 | 0.2 |
| 6    | N | 0.54 | 4  | 2  | 3  | 1  | 0.8 | 0.4 |
| 7    | N | 0.53 | 4  | 3  | 2  | 1  | 0.8 | 0.6 |
| 8    | N | 0.51 | 4  | 4  | 1  | 1  | 0.8 | 0.8 |
| 9    | P | 0.50 | 5  | 4  | 1  | 0  | 1.0 | 0.8 |
| 10   | N | 0.40 | 5  | 5  | 0  | 0  | 1.0 | 1.0 |



1. 首先将数据按照"概率"从高到低排序
2. 统计总的正例(P)和负例(N)数量：正例(P): 5个 (编号1,2,4,5,9)，负例(N): 5个 (编号3,6,7,8,10)
3. 按照排序依次处理每个样本，计算当前阈值下的TPR和FPR
4. 在坐标系上标出这些点，并按顺序用直线连接它们。
5. 最后画一条从(0,0)到(1,1)的对角线，表示随机猜测的性能。

| 阈值    | TP | FP | TPR | FPR | 点坐标       |
|-------|----|----|-----|-----|-----------|
| 无(全负) | 0  | 0  | 0   | 0   | (0,0)     |
| >0.90 | 1  | 0  | 0.2 | 0   | (0,0.2)   |
| >0.80 | 2  | 0  | 0.4 | 0   | (0,0.4)   |
| >0.70 | 2  | 1  | 0.4 | 0.2 | (0.2,0.4) |
| >0.60 | 3  | 1  | 0.6 | 0.2 | (0.2,0.6) |
| >0.55 | 4  | 1  | 0.8 | 0.2 | (0.2,0.8) |
| >0.54 | 4  | 2  | 0.8 | 0.4 | (0.4,0.8) |
| >0.53 | 4  | 3  | 0.8 | 0.6 | (0.6,0.8) |

|       |   |   |     |     |           |
|-------|---|---|-----|-----|-----------|
| >0.51 | 4 | 4 | 0.8 | 0.8 | (0.8,0.8) |
| >0.50 | 5 | 4 | 1.0 | 0.8 | (0.8,1.0) |
| >0.40 | 5 | 5 | 1.0 | 1.0 | (1.0,1.0) |

结论：曲线越靠近左上角，模型性能越好，曲线下面积(AUC)越大，模型区分能力越强

## 第九章

### P263 例9.1 后向传播算法

下图定义了一个多层前馈神经网络，令其学习率为0.9，第一个训练元组为 $X=\{1, 0, 1\}$




图 9.5 多层前馈神经网络的一个例子

表 9.1 初始输入、权重和偏倚值

| $x_1$ | $x_2$ | $x_3$ | $w_{14}$ | $w_{15}$ | $w_{24}$ | $w_{25}$ | $w_{34}$ | $w_{35}$ | $w_{46}$ | $w_{56}$ | $\theta_4$ | $\theta_5$ | $\theta_6$ |
|-------|-------|-------|----------|----------|----------|----------|----------|----------|----------|----------|------------|------------|------------|
| 1     | 0     | 1     | 0.2      | -0.3     | 0.4      | 0.1      | -0.5     | 0.2      | -0.3     | -0.2     | -0.4       | 0.2        | 0.1        |

表 9.2 净输入和输出的计算

| 单元 $j$ | 净输入 $I_j$                                     | 输出 $O_j$                      |
|--------|-----------------------------------------------|-------------------------------|
| 4      | $0.2 + 0 - 0.5 - 0.4 = -0.7$                  | $1 + (1 + e^{0.7}) = 0.33$    |
| 5      | $-0.3 + 0 + 0.2 + 0.2 = 0.1$                  | $1 + (1 + e^{-0.1}) = 0.525$  |
| 6      | $-(0.3)(0.332) - (0.2)(0.525) + 0.1 = -0.105$ | $1 + (1 + e^{0.105}) = 0.474$ |

表 9.3 每个节点误差的计算

| 单元 $j$ | $Err_j$                                       |
|--------|-----------------------------------------------|
| 6      | $(0.474)(1 - 0.474)(1 - 0.474) = 0.1311$      |
| 5      | $(0.525)(1 - 0.525)(0.1311)(-0.2) = -0.0065$  |
| 4      | $(0.332)(1 - 0.332)(0.1311)(-0.3) = -0.02087$ |

表 9.4 权重和偏倚更新的计算

| 权重或偏差      | 新值                                     |
|------------|----------------------------------------|
| $w_{46}$   | $-0.3 + (0.9)(0.1311)(0.332) = -0.261$ |
| $w_{56}$   | $-0.2 + (0.9)(0.1311)(0.525) = -0.138$ |
| $w_{14}$   | $0.2 + (0.9)(-0.0087)(1) = 0.192$      |
| $w_{15}$   | $-0.3 + (0.9)(-0.0065)(1) = -0.306$    |
| $w_{24}$   | $0.4 + (0.9)(-0.0087)(0) = 0.4$        |
| $w_{25}$   | $0.1 + (0.9)(-0.0065)(0) = 0.1$        |
| $w_{34}$   | $-0.5 + (0.9)(-0.0087)(1) = -0.508$    |
| $w_{35}$   | $0.2 + (0.9)(-0.0065)(1) = 0.194$      |
| $\theta_6$ | $0.1 + (0.9)(0.1311) = 0.218$          |
| $\theta_5$ | $0.2 + (0.9)(-0.0065) = 0.194$         |
| $\theta_4$ | $-0.4 + (0.9)(-0.0087) = -0.408$       |

图中表9.2第一行输出 $O_j$ 为0.332，表9.3第三行结果为-0.0087

## 第十章

### P295 例10.2 K-均值会计算第一轮

#### 一维K-均值，参考第三章：Kmeans算法的处理流程

#### 二维算法步骤：

1. 初始化中心点随机选择K个数据点作为初始簇中心（质心）。
2. 分配数据点到最近簇计算每个数据点到所有质心的距离（通常用欧氏距离），将其分配到最近的簇。欧氏距离公式：

$$d(\mathbf{x}, \mathbf{c}) = \sqrt{\sum_{i=1}^n (x_i - c_i)^2}$$

3. 重新计算质心对每个簇，计算其所有数据点的均值，作为新质心。
4. 迭代直至收敛重复步骤2-3，直到质心不再显著变化（或达到最大迭代次数）。

#### 示例演示

假设有以下二维数据点，分成2个簇（ $K=2$ ）：数据点 =  $[(1,1), (1,2), (10,10), (10,11)]$

步骤1：随机初始化质心，例如选  $(1,1)$  和  $(10,10)$  作为初始质心  $c_1, c_2$ 。

**步骤2：**计算每个点到质心的距离并分配簇：

- 点  $(1,1)$  到  $c_1$  距离为 0，分配到簇1。
- 点  $(1,2)$  到  $c_1$  距离 1，到  $c_2$  距离  $\sim 12.04$ ，分配到簇1。
- 点  $(10,10)$  到  $c_2$  距离 0，分配到簇2。
- 点  $(10,11)$  到  $c_2$  距离 1，到  $c_1$  距离  $\sim 13.45$ ，分配到簇2。

**当前簇分配：** 簇1 =  $[(1,1), (1,2)]$ ，簇2 =  $[(10,10), (10,11)]$

**步骤3：**重新计算质心：

- 新  $c_1 = \left( \frac{1+1}{2}, \frac{1+2}{2} \right) = (1, 1.5)$
- 新  $c_2 = \left( \frac{10+10}{2}, \frac{10+11}{2} \right) = (10, 10.5)$

**步骤4：**重复分配数据点：所有点的新分配结果与之前相同，质心不再变化，算法终止。

**最终结果：** 簇1 =  $[(1,1), (1,2)]$ ，质心  $(1, 1.5)$ ，簇2 =  $[(10,10), (10,11)]$ ，质心  $(10, 10.5)$

**P300 四个距离公式：最小，最大，均值，平均**

## 1. 单链（Single Linkage | 最小距离）

**定义：**两个簇之间的距离定义为它们中最近的两个点之间的距离。

$$D_{\min}(C_1, C_2) = \min_{\substack{\mathbf{x} \in C_1 \\ \mathbf{y} \in C_2}} d(\mathbf{x}, \mathbf{y})$$

**特点：**容易形成“链式效应”（Chaining），适合发现非球形簇。对噪声敏感（可能因离群点误合并簇）。

**示例：**

- 簇1: A(1,1), B(2,2)，簇2: C(5,5), D(6,6)
- 最小距离 =  $d(B, C) = \sqrt{(5-2)^2 + (5-2)^2} = 3\sqrt{2}$

## 2. 全链（Complete Linkage | 最大距离）

**定义：**两个簇之间的距离定义为它们中最远的两个点之间的距离。

$$D_{\min}(C_1, C_2) = \max_{\substack{\mathbf{x} \in C_1 \\ \mathbf{y} \in C_2}} d(\mathbf{x}, \mathbf{y})$$

**特点：**倾向于生成紧凑的球形簇，对噪声鲁棒性强。可能因最大距离限制导致簇分裂过度。

**示例：**

- 同上数据，最大距离 =  $d(A, D) = \sqrt{(6-1)^2 + (6-1)^2} = 5\sqrt{2}$

## 3. 均值距离（Mean Linkage | 质心距离）

**定义：**两个簇之间的距离定义为它们的质心（均值点）之间的距离。

$$D_{\text{mean}}(C_1, C_2) = d(\mu_1, \mu_2), \quad \text{其中} \quad \mu_k = \frac{1}{|C_k|} \sum_{\mathbf{x} \in C_k} \mathbf{x}$$

**特点：**计算效率高，适合大数据集。对非凸形状簇效果可能不佳。

**示例：**

- 簇1质心：  $\mu_1 = \left( \frac{1+2}{2}, \frac{1+2}{2} \right) = (1.5, 1.5)$
- 簇2质心：  $\mu_2 = \left( \frac{5+6}{2}, \frac{5+6}{2} \right) = (5.5, 5.5)$
- 距离 =  $\sqrt{(5.5 - 1.5)^2 + (5.5 - 1.5)^2} = 4\sqrt{2}$

#### 4. 平均距离 (Average Linkage | UPGMA)

**定义：**两个簇之间的距离定义为它们中所有点对距离的平均值。

$$D_{\text{avg}}(C_1, C_2) = \frac{1}{|C_1||C_2|} \sum_{\substack{\mathbf{x} \in C_1 \\ \mathbf{y} \in C_2}} d(\mathbf{x}, \mathbf{y})$$

**特点：**平衡单链和全链，避免极端情况。 计算量较大（需遍历所有点对）。

**示例：**

- 点对距离：  $d(A, C), d(A, D), d(B, C), d(B, D)$
- 平均距离 =  $\frac{4\sqrt{2} + 5\sqrt{2} + 3\sqrt{2} + 4\sqrt{2}}{4} = 4\sqrt{2}$

#### 对比总结

| 方法 | 计算方式     | 优点       | 缺点      |
|----|----------|----------|---------|
| 单链 | 最小点对距离   | 能发现复杂形状  | 易受噪声影响  |
| 全链 | 最大点对距离   | 鲁棒性强，簇紧凑 | 可能过度分裂  |
| 均值 | 质心距离     | 计算高效     | 对非凸簇效果差 |
| 平均 | 所有点对平均距离 | 平衡性较好    | 计算复杂度高  |

## 第十一章

### P328 例11.7 EM算法的模糊聚类 第一轮计算

#### 1. 初始化

- **输入数据：**6个点的坐标  $a(3,3), b(4,10), c(9,6), d(14,8), e(18,11), f(21,7)$ 。
- **初始聚类中心：**随机选择两个点  $c_1 = a, c_2 = b$ 。

## 2. 第一轮迭代

### E步 (Expectation) : 计算隶属度

对每个点 $o$ , 计算其属于  $c_1$  和  $c_2$  的隶属度  $w_{o,c_j}$  :

$$w_{o,c_1} = \frac{\text{dist}(o, c_2)^2}{\text{dist}(o, c_1)^2 + \text{dist}(o, c_2)^2}, \quad w_{o,c_2} = \frac{\text{dist}(o, c_1)^2}{\text{dist}(o, c_1)^2 + \text{dist}(o, c_2)^2}$$

示例计算:

- 点a:

- $\text{dist}(a, c_1) = 0, \text{dist}(a, c_2) = \sqrt{(4-3)^2 + (10-3)^2} = \sqrt{50}$

- $w_{a,c_1} = \frac{50}{0+50} = 1, w_{a,c_2} = 0$  (直接属于  $c_1$ )。

- 点c:

- $\text{dist}(c, c_1) = \sqrt{(9-3)^2 + (6-3)^2} = \sqrt{45}$

- $\text{dist}(c, c_2) = \sqrt{(9-4)^2 + (6-10)^2} = \sqrt{41}$

- $w_{c,c_1} = \frac{41}{45+41} \approx 0.48, w_{c,c_2} \approx 0.52$ 。

其他点同理, 得到第一轮隶属度矩阵:

$$M^T = \begin{bmatrix} 1 & 0 & 0.48 & 0.42 & 0.41 & 0.47 \\ 0 & 1 & 0.52 & 0.58 & 0.59 & 0.53 \end{bmatrix}$$

### M步 (Maximization) : 更新聚类中心

根据隶属度重新计算中心  $c_j$  (公式11.12) :

$$c_j = \frac{\sum_o w_{o,c_j}^2 \cdot o}{\sum_o w_{o,c_j}^2}$$

计算  $c_1$  (6个点的坐标 a(3,3), b(4,10), c(9,6), d(14,8), e(18,11), f(21,7)) :

- 分子 (x坐标) :

$$1^2 \times 3 + 0^2 \times 4 + 0.48^2 \times 9 + 0.42^2 \times 14 + 0.41^2 \times 18 + 0.47^2 \times 21 \approx 8.47$$

- 分母:  $1^2 + 0^2 + 0.48^2 + 0.42^2 + 0.41^2 + 0.47^2 \approx 1.88$

- 因此  $c_1 = (8.47, 5.12)$ 。

同理计算  $c_2 = (10.42, 8.99)$ 。

## 3. 后续迭代

重复E步和M步, 直到中心变化小于阈值或达到最大迭代次数。

### 关键点总结

- 隶属度计算:** 点越靠近某中心, 隶属度越高, 且所有簇的隶属度之和为1。公式中距离平方的倒数比例保证了模糊性。

2. **中心更新**：新中心是所有点的加权平均，权重为隶属度的平方。
3. **与K均值的区别**：K均值是硬分配（每个点仅属于一个簇），而模糊聚类允许软分配（隶属度概率）。
4. **收敛性**：通过迭代优化，中心逐渐稳定，SSE（平方误差和）最小化。

P341 例11.19 基于测地距的度量

测地距(Geodesic Distance)

定义：图中两个顶点之间的最短路径的边数，非连通顶点间的测地距：无穷大




图 11.13 图  $G$ ，其中顶点  $c, d$  和  $e$  都是外围顶点

1. 计算所有顶点对之间的测地距（最短路径边数）

| 顶点对                   | 最短路径      | 测地距 |
|-----------------------|-----------|-----|
| $a \leftrightarrow b$ | $a-b$     | 1   |
| $a \leftrightarrow c$ | $a-b-c$   | 2   |
| $a \leftrightarrow d$ | $a-d$     | 1   |
| $a \leftrightarrow e$ | $a-e$     | 1   |
| $b \leftrightarrow c$ | $b-c$     | 1   |
| $b \leftrightarrow d$ | $b-a-d$   | 2   |
| $b \leftrightarrow e$ | $b-a-e$   | 2   |
| $c \leftrightarrow d$ | $c-b-a-d$ | 3   |
| $c \leftrightarrow e$ | $c-b-a-e$ | 3   |
| $d \leftrightarrow e$ | $d-e$     | 1   |

2. 计算每个顶点的离心率 (eccentricity)

离心率是顶点到其他顶点的最大测地距。

- **a 的离心率**  $\text{eccen}(a) = \max\{d(a, b), d(a, c), d(a, d), d(a, e)\} = \max\{1, 2, 1, 1\} = 2$
- **b 的离心率**  $\text{eccen}(b) = \max\{d(b, a), d(b, c), d(b, d), d(b, e)\} = \max\{1, 1, 2, 2\} = 2$
- **c 的离心率**  $\text{eccen}(c) = \max\{d(c, a), d(c, b), d(c, d), d(c, e)\} = \max\{2, 1, 3, 3\} = 3$
- **d 的离心率**  $\text{eccen}(d) = \max\{d(d, a), d(d, b), d(d, c), d(d, e)\} = \max\{1, 2, 3, 1\} = 3$
- **e 的离心率**  $\text{eccen}(e) = \max\{d(e, a), d(e, b), d(e, c), d(e, d)\} = \max\{1, 2, 3, 1\} = 3$

3. 计算图的半径 (radius) 和直径 (diameter)

- **半径**  $r = \min\{\text{eccen}(v) \mid v \in V\} = \min\{2, 2, 3, 3, 3\} = 2$
- **直径**  $d = \max\{\text{eccen}(v) \mid v \in V\} = \max\{2, 2, 3, 3, 3\} = 3$

4. 识别中心顶点和外围顶点

- **中心顶点** (离心率 = 半径 = 2) : a和b
- **外围顶点** (离心率 = 直径 = 3) : c, d, e

5. 关键观察

- **半径  $\neq$  直径的一半** ( $2 \neq \frac{3}{2}$ ) , 这与某些对称图不同。
- **最长最短路径** 出现在  $c \leftrightarrow d$  或  $c \leftrightarrow e$  , 测地距为 3。
- **a 和 b 是中心** , 因为它们到最远顶点的距离最小 (离心率最小) 。
- **c, d, e 是外围** , 因为它们至少有一个顶点对的距离达到直径 3。